ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Báo Cáo Lab 1

ĐỀ TÀI

Dự đoán giá nhà với hồi quy tuyến tính

Lớp: 24TNT1

Họ và tên	*MSSV*
Nguyễn Cao Bản	**24122029**

Giáo viên hướng dẫn:

TS. Cấn Trần Thành Trung

ThS. Nguyễn Ngọc Toàn

Mục lục

Lời cảm ơn **5**

Giới thiệu **6**

1 Nền tảng toán học **7**

1.1 Xác suất thống kê . . . 7
1.1.1 Kỳ vọng và phương sai . . . 7
1.1.2 Hiệp phương sai . . . 7
1.2 Đại số tuyến tính . . . 8
1.2.1 Vector . . . 8
1.2.2 Ma trận . . . 8
1.2.3 Phép nhân ma trận . . . 9
1.2.4 Chuyển vị ma trận . . . 9
1.2.5 Ma trận đơn vị . . . 9
1.2.6 Ma trận nghịch đảo . . . 10
1.2.7 Không gian vector . . . 10
1.2.8 Tích vô hướng . . . 10
1.2.9 Eigenvalue và Eigenvector . . . 11
1.2.10 Ma trận đối xứng . . . 11
1.3 Hồi quy tuyến tính . . . 11
1.3.1 Mô hình hồi quy tuyến tính . . . 11
1.3.2 Hàm mất mát . . . 12
1.3.3 Gradient của hàm mất mát . . . 12
1.3.4 Gradient Descent . . . 13
1.3.5 Ý nghĩa hình học . . . 13
1.3.6 Nghiệm đóng của hồi quy tuyến tính . . . 13
1.4 Regularization . . . 14
1.4.1 Ridge Regression . . . 14
1.4.2 Lasso Regression . . . 15
1.4.3 So sánh Ridge và Lasso . . . 16
1.5 Principal Component Analysis (PCA) . . . 16
1.5.1 Chuẩn hóa dữ liệu . . . 16
1.5.2 Ma trận hiệp phương sai . . . 16
1.5.3 Eigen Decomposition . . . 17
1.5.4 Explained Variance Ratio . . . 17
1.5.5 Chiếu dữ liệu . . . 17
1.5.6 Ý nghĩa của PCA . . . 18

2 Phân tích và Khám phá Dữ liệu **19**
2.1 Tổng quan về dữ liệu . . . 19
2.1.1 Hiển thị dữ liệu ban đầu . . . 22
2.1.2 Thống kê mô tả dữ liệu số . . . 22
2.1.3 Thông tin dữ liệu thiếu . . . 24
2.1.4 Thông tin mở rộng dữ liệu . . . 25
2.1.5 Nhận xét . . . 27
2.2 Trực quan hóa dữ liệu . . . 28
2.2.1 Ma trận tương quan các đặc trưng số . . . 28
2.2.2 Histogram các đặc trưng số . . . 30
2.2.3 Biểu đồ phân tán của các đặc trưng số . . . 33
2.2.4 Boxplot của các đặc trưng categorical . . . 34

3 Tiền xử lý dữ liệu **37**
3.1 Xử lý giá trị khuyết (Missing Values Handling) . . . 37
3.1.1 Mô tả vấn đề . . . 37
3.1.2 Phương pháp tiếp cận . . . 38
3.1.3 Lưu ý quan trọng . . . 39
3.2 Xử lý ngoại lai . . . 39
3.2.1 Mô tả vấn đề . . . 39
3.2.2 Phương pháp tiếp cận . . . 39
3.3 Mã hóa biến phân loại . . . 40
3.3.1 Mô tả vấn đề . . . 40
3.3.2 Phương pháp 1: Mã hóa kết hợp (Hybrid Encoding) . . . 40
3.3.3 Phương pháp 2: One-hot Encoding toàn bộ (Full One-hot) . . . 41
3.4 Biến đổi đặc trưng . . . 42
3.4.1 Mô tả vấn đề . . . 42
3.4.2 Xử lý độ lệch (Skewness Correction) . . . 42
3.4.3 Tạo đặc trưng đa thức . . . 43
3.5 Tạo đặc trưng mới . . . 43
3.5.1 Mô tả vấn đề . . . 43
3.5.2 Các đặc trưng mới được tạo . . . 43
3.5.3 Lưu ý . . . 44
3.6 Giảm nhiễu và đa cộng tuyến . . . 44
3.6.1 Mô tả vấn đề . . . 44
3.6.2 Các bước thực hiện . . . 44
3.7 Chuẩn hóa dữ liệu . . . 45
3.7.1 Mô tả vấn đề . . . 45
3.7.2 Phương pháp tiếp cận . . . 45
3.8 Giảm chiều dữ liệu (Dimensionality Reduction) . . . 46
3.8.1 Mô tả vấn đề . . . 46
3.8.2 Phương pháp PCA . . . 47
3.8.3 Lưu ý . . . 47

4 Hồi quy Tuyến tính: Từ Phương trình chuẩn đến Tối ưu hóa Gradient **48**
4.1 Giới thiệu chung . . . 48
4.2 Phương pháp Phương trình chuẩn (Ordinary Least Squares) . . . 48
4.2.1 Xây dựng Ma trận mở rộng . . . 48
4.2.2 Giải thuật Moore-Penrose Pseudoinverse . . . 48
4.3 Tối ưu hóa bằng Gradient Descent . . . 49

4.3.1 Giới thiệu: Ý tưởng từ người leo núi . . . 49
4.3.2 Mini-batch Gradient Descent: Sự cân bằng giữa tốc độ và độ ổn định 50
4.3.3 Cơ chế Momentum: Tận dụng quán tính . . . 50
4.4 Kỹ thuật Điều chuẩn (Regularization): Kiểm soát sự phức tạp . . . 50
4.4.1 L2 Regularization (Ridge Regression) . . . 50
4.4.2 L1 Regularization (Lasso Regression) . . . 50
4.4.3 Elastic Net: Sự kết hợp hoàn hảo . . . 51
4.5 Ổn định hóa bằng Gradient Clipping . . . 51
4.6 Điều kiện dừng sớm (Early Stopping) . . . 51

5 Phương pháp đánh giá mô hình 52
5.1 Mean Absolute Error . . . 52
5.1.1 Ý nghĩa của MAE . . . 52
5.1.2 Lý do lựa chọn MAE để đánh giá . . . 52
5.1.3 Ưu điểm của MAE . . . 53
5.2 Đánh giá mô hình bằng K-Fold Cross Validation . . . 53
5.2.1 Nguyên lý hoạt động và Ưu điểm . . . 53
5.2.2 Triển khai thuật toán và Chống rò rỉ dữ liệu (Data Leakage) . . . 54
5.2.3 Tích hợp các tùy chọn tối ưu hóa đặc trưng . . . 54
5.2.4 Đánh giá hiệu suất . . . 54

6 Kết quả thực nghiệm 55
6.1 Mô hình sử dụng toàn bộ đặc trưng (Yêu cầu 2a) . . . 55
6.1.1 Mô tả . . . 55
6.1.2 Công thức hồi quy . . . 55
6.1.3 Kết quả đánh giá . . . 58
6.2 Lựa chọn đặc trưng đơn tốt nhất (Yêu cầu 2b) . . . 59
6.2.1 Mô tả . . . 59
6.2.2 Các đặc trưng được lựa chọn . . . 59
6.2.3 Phương pháp đánh giá . . . 59
6.3 Thiết kế phương án đặc trưng mới (Yêu cầu 2c) . . . 60
6.3.1 Mô tả . . . 60
6.3.2 Phương án 1: Feature Engineering + Denoising . . . 61
6.3.3 Phương án 2: One-hot Encoding + PCA . . . 61
6.3.4 Phương án 3: Feature Selection bằng Lasso . . . 62
6.3.5 Đánh giá bằng K-Fold Cross Validation . . . 63
6.3.6 Kết quả thực nghiệm . . . 63
6.3.7 Huấn luyện mô hình cuối cùng . . . 64
6.3.8 Kết quả trên tập kiểm tra . . . 66
6.3.9 So sánh MAE validation với MAE CV của phương án được chọn . . . 67

7 KẾT LUẬN 68
7.1 So sánh kết quả giữa các yêu cầu . . . 68
7.2 Nhận xét về các phương pháp tiếp cận . . . 68
7.2.1 Yêu cầu 2a: Toàn bộ đặc trưng . . . 68
7.2.2 Yêu cầu 2b: Lựa chọn đặc trưng đơn tốt nhất . . . 69
7.2.3 Yêu cầu 2c: Feature Engineering + Denoising . . . 69
7.3 Vai trò của biến đổi và lựa chọn đặc trưng . . . 69
7.4 Kết luận chung . . . 70

8 Tài liệu tham khảo **71**

Lời cảm ơn

Lời đầu tiên, em xin gửi lời cảm ơn chân thành đến các giảng viên đã cung cấp cũng như những hướng dẫn gợi ý về mục tiêu và yêu cầu của bài tập Lab1. Những tài liệu này đã tạo nền tảng quan trọng giúp em tiếp cận bài toán dự đoán giá nhà một cách thực tiễn.
Em xin đặc biệt cảm ơn giảng viên phụ trách môn học **Phương pháp toán cho trí tuệ nhân tạo**, người đã truyền đạt những kiến thức quý báu về mô hình hồi quy tuyến tính (Linear Regression) và các phương pháp đánh giá mô hình như MAE và K-fold cross-validation.

Mặc dù đã cố gắng vận dụng các kiến thức toán học và kỹ thuật xử lý dữ liệu để hoàn thành bài làm một cách tốt nhất, báo cáo chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp và phê bình từ quý thầy cô để kiến thức của em ngày càng hoàn thiện hơn.

Trong quá trình thực hiện bài tập Lab 1 - "Dự đoán giá nhà với hồi quy tuyến tính"thuộc học phần Phương pháp toán cho trí tuệ nhân tạo, em xin cam đoan:

- Bài làm này là kết quả của quá trình học tập và nghiên cứu độc lập của cá nhân em.
- Các nội dung trong bài làm được thực hiện dựa trên kiến thức nền tảng từ bài giảng và tài liệu hướng dẫn.
- Em có sử dụng Trí tuệ nhân tạo (AI) và các nguồn tài liệu trên Internet (như Stack Overflow, các diễn đàn Machine Learning, các trang mã nguồn uy tín, các quyển sách) và tham khảo các anh chị khóa k23 ngành trí tuệ nhân tạo **chỉ với mục đích tham khảo các khái niệm lý thuyết và gợi ý về cách tiếp cận trực quan hóa dữ liệu**.
- Em hoàn toàn không sử dụng AI để tự động tạo ra mã nguồn (source code) hay viết hộ nội dung báo cáo. Toàn bộ mã nguồn trong file notebook và các phân tích trong báo cáo này đều do em tự thực hiện và chịu trách nhiệm.

Em hiểu rõ quy định của môn học về việc nghiêm cấm các hành vi sử dụng AI để hoàn thành bài làm và xin chấp nhận hình thức kỷ luật cao nhất (0 điểm) nếu có bất kỳ sự gian lận nào được phát hiện

Em xin chân thành cảm ơn!

Giới thiệu

Mục tiêu của Lab 1 là xây dựng các mô hình hồi quy tuyến tính để dự đoán giá bán nhà dựa trên bộ dữ liệu Ames Housing.

Thông tin sinh viên thực hiện:

- Họ và tên: [**Nguyễn Cao Bản**]
- Mã số sinh viên: [**24122029**]
- Lớp: [**24TNT1**]
- Link GitHub: https://github.com/caoban123/MathForAI

Bảng nhiệm vụ chi tiết:

Thành phần	**Yêu cầu**	**Nhiệm vụ chi tiết**
Yêu cầu 1	EDA	Phân tích khám phá dữ liệu, kiểm tra giá trị thiếu, vẽ biểu đồ phân phối và ma trận tương quan.
Yêu cầu 2a	Full Model	Huấn luyện mô hình hồi quy tuyến tính sử dụng toàn bộ đặc trưng, trình bày công thức và báo cáo MAE.
Yêu cầu 2b	Single Feature	Thực hiện K-fold cross-validation để chọn ra đặc trưng đơn lẻ tốt nhất và huấn luyện mô hình tương ứng.
Yêu cầu 2c	Custom Models	Thiết kế 03 phương án biến đổi đặc trưng (PCA, Lasso Selector, Feature Engineering) và chọn lọc qua Cross-validation.

Các thư viện và công nghệ sử dụng:

- **Numpy**: Thư viện Python hỗ trợ tính toán số học và xử lý ma trận.
- **Pandas**: Công cụ chính để thao tác, làm sạch và quản lý dữ liệu bảng (DataFrame)].
- **Matplotlib / Seaborn**: Bộ thư viện dùng để trực quan hóa dữ liệu, vẽ biểu đồ phân tích và biểu đồ sai số.
- **Jupyter Notebook**: Môi trường làm việc tương tác cho phép kết hợp mã thực thi, văn bản mô tả (Markdown) và các công thức toán học LaTeX.
- **Visual Studio Code**: Trình soạn thảo mã nguồn và quản lý môi trường ảo (IDE)

Cam kết: Toàn bộ các bước huấn luyện mô hình và tính toán đều tuân thủ yêu cầu không sử dụng các thư viện hỗ trợ training tự động (như scikit-learn) theo quy định của bài Lab.

Chương 1

Nền tảng toán học

1.1 Xác suất thống kê

Trong bài toán dự đoán giá nhà, dữ liệu được xem như các mẫu quan sát ngẫu nhiên từ một phân phối xác suất chưa biết. Do đó, các khái niệm trong xác suất thống kê được sử dụng để mô tả và phân tích dữ liệu.

1.1.1 Kỳ vọng và phương sai

Cho biến ngẫu nhiên X, kỳ vọng được định nghĩa là:

$$E(X) = \mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Phương sai đo mức độ phân tán của dữ liệu:

$$Var(X) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2$$

Độ lệch chuẩn:

$$\sigma = \sqrt{Var(X)}$$

Các đại lượng này được sử dụng trong bước chuẩn hóa dữ liệu trước khi huấn luyện mô hình.

1.1.2 Hiệp phương sai

Hiệp phương sai đo mối quan hệ tuyến tính giữa hai biến:

$$Cov(X, Y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu_x)(y_i - \mu_y)$$

Nếu:

- $Cov > 0$: hai biến tương quan thuận
- $Cov < 0$: hai biến tương quan nghịch
- $Cov = 0$: hai biến độc lập tuyến tính

Ma trận hiệp phương sai:

$$Cov(X) = \frac{1}{n} X^T X$$

Ma trận này được sử dụng trong phương pháp PCA.

1.2 Đại số tuyến tính

Đại số tuyến tính là nền tảng quan trọng trong việc biểu diễn dữ liệu và thực hiện các phép toán trên không gian nhiều chiều. Trong các bài toán xử lý dữ liệu, dữ liệu thường được biểu diễn dưới dạng vector và ma trận.

1.2.1 Vector

Vector là một tập hợp các số được sắp xếp theo thứ tự. Vector n chiều được biểu diễn như sau:

$$x = \begin{bmatrix} x_1 \\ x_2 \\ ... \\ x_n \end{bmatrix}$$

Vector có thể được xem như một điểm trong không gian n chiều:

$$x \in R^n$$

Độ dài của vector được định nghĩa bởi chuẩn Euclid:

$$||x|| = \sqrt{x_1^2 + x_2^2 + ... + x_n^2}$$

1.2.2 Ma trận

Ma trận là một bảng gồm các phần tử được sắp xếp theo hàng và cột:

$$A = \begin{bmatrix} a_{11} & a_{12} & ... & a_{1n} \\ a_{21} & a_{22} & ... & a_{2n} \\ ... & & & \\ a_{m1} & a_{m2} & ... & a_{mn} \end{bmatrix}$$

Ma trận có kích thước:

$$A \in R^{m \times n}$$

Trong đó:

- m là số hàng
- n là số cột

1.2.3 Phép nhân ma trận

Cho hai ma trận:

$$A \in R^{m \times n}$$

$$B \in R^{n \times p}$$

Tích của hai ma trận:

$$C = AB$$

Trong đó:

$$C \in R^{m \times p}$$

Phần tử của ma trận kết quả:

$$c_{ij} = \sum_{k=1}^{n} a_{ik} b_{kj}$$

1.2.4 Chuyển vị ma trận

Chuyển vị của ma trận A được ký hiệu:

$$A^T$$

Nếu:

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

Thì:

$$A^T = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}$$

1.2.5 Ma trận đơn vị

Ma trận đơn vị có dạng:

$$I = \begin{bmatrix} 1 & 0 & ... & 0 \\ 0 & 1 & ... & 0 \\ ... & & & \\ 0 & 0 & ... & 1 \end{bmatrix}$$

Tính chất:

$$AI = IA = A$$

1.2.6 Ma trận nghịch đảo

Ma trận nghịch đảo của A được ký hiệu:

$$A^{-1}$$

Thoả mãn:

$$AA^{-1} = A^{-1}A = I$$

Không phải mọi ma trận đều có nghịch đảo. Ma trận có nghịch đảo khi định thức khác 0:

$$det(A) \neq 0$$

1.2.7 Không gian vector

Không gian vector là tập hợp các vector thoả mãn các phép toán:

- Cộng vector
- Nhân vector với số vô hướng

Cho hai vector:

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, y = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}$$

Cộng vector:

$$x + y = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \end{bmatrix}$$

Nhân vô hướng:

$$\alpha x = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \end{bmatrix}$$

1.2.8 Tích vô hướng

Tích vô hướng của hai vector:

$$x \cdot y = \sum_{i=1}^{n} x_i y_i$$

Hoặc dạng ma trận:

$$x^T y$$

Tích vô hướng dùng để đo độ tương quan giữa hai vector.

1.2.9 Eigenvalue và Eigenvector

Cho ma trận vuông A, nếu tồn tại vector v và số vô hướng λ thỏa mãn:

$$Av = \lambda v$$

thì:

- v gọi là eigenvector
- λ gọi là eigenvalue

Eigenvector biểu diễn hướng đặc trưng của ma trận.
Eigenvalue biểu diễn mức độ quan trọng của hướng đó.

1.2.10 Ma trận đối xứng

Ma trận đối xứng có dạng:

$$A = A^T$$

Ma trận đối xứng có tính chất:

- Eigenvalue luôn là số thực
- Eigenvector trực giao

Đây là tính chất quan trọng trong nhiều bài toán đại số tuyến tính.

1.3 Hồi quy tuyến tính

Hồi quy tuyến tính (Linear Regression) là phương pháp học có giám sát được sử dụng để mô hình hóa mối quan hệ tuyến tính giữa biến đầu vào và biến đầu ra. Trong bài toán dự đoán giá nhà, hồi quy tuyến tính được sử dụng để dự đoán giá trị liên tục dựa trên các đặc trưng của căn nhà.

1.3.1 Mô hình hồi quy tuyến tính

Giả sử tập dữ liệu gồm n mẫu và d đặc trưng. Khi đó:

$$X \in R^{n \times d}$$

Trong đó:

- n là số lượng mẫu
- d là số lượng đặc trưng

Vector mục tiêu:

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}$$

Vector trọng số:

$$w = \begin{bmatrix} w_1 \\ w_2 \\ \dots \\ w_d \end{bmatrix}$$

Mô hình hồi quy tuyến tính có dạng:

$$\hat{y} = Xw + b$$

Trong đó:

- X là ma trận đặc trưng
- w là vector trọng số
- b là hệ số bias
- $\hat{y}$ là vector giá trị dự đoán

Bias có thể được gộp vào vector trọng số bằng cách thêm một cột toàn số 1 vào ma trận X.

1.3.2 Hàm mất mát

Để đánh giá mức độ sai lệch giữa giá trị dự đoán và giá trị thực, sử dụng hàm mất mát bình phương sai số (Mean Squared Error):

$$J(w) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Viết dưới dạng ma trận:

$$J(w) = \frac{1}{n}||y - Xw||^2$$

Hàm mất mát này đo độ sai khác trung bình giữa giá trị thực và giá trị dự đoán. Mục tiêu của bài toán là tìm vector w sao cho hàm mất mát nhỏ nhất.

1.3.3 Gradient của hàm mất mát

Để tối ưu hàm mất mát, ta tính đạo hàm theo vector trọng số w:

$$\nabla J(w) = \frac{\partial J(w)}{\partial w}$$

Gradient của hàm mất mát có dạng:

$$\nabla J(w) = \frac{2}{n} X^T (Xw - y)$$

Trong đó:

- X^T là ma trận chuyển vị
- $(Xw - y)$ là vector sai số

Gradient biểu diễn hướng tăng nhanh nhất của hàm mất mát. Để tối thiểu hóa hàm mất mát, ta cập nhật trọng số theo hướng ngược lại với gradient.

1.3.4 Gradient Descent

Gradient Descent là thuật toán tối ưu lặp để tìm giá trị nhỏ nhất của hàm mất mát. Trọng số được cập nhật theo công thức:

$$w = w - \alpha \nabla J(w)$$

Trong đó:

- α là learning rate
- $\nabla J(w)$ là gradient của hàm mất mát

Thay gradient vào công thức cập nhật:

$$w = w - \alpha \frac{2}{n} X^T (Xw - y)$$

Thuật toán được thực hiện lặp lại cho đến khi:

- Hàm mất mát hội tụ
- Đạt số lần lặp tối đa

1.3.5 Ý nghĩa hình học

Trong không gian nhiều chiều, hồi quy tuyến tính tìm một siêu phẳng:

$$y = w_1 x_1 + w_2 x_2 + ... + w_d x_d + b$$

Sao cho tổng bình phương khoảng cách giữa các điểm dữ liệu và siêu phẳng là nhỏ nhất.

1.3.6 Nghiệm đóng của hồi quy tuyến tính

Ngoài Gradient Descent, hồi quy tuyến tính còn có nghiệm giải tích:

$$w = (X^T X)^{-1} X^T y$$

Công thức này được gọi là phương trình chuẩn (Normal Equation). Tuy nhiên phương pháp này tốn chi phí tính toán lớn khi số đặc trưng nhiều, do đó Gradient Descent thường được sử dụng trong thực tế.

1.4 Regularization

Trong hồi quy tuyến tính, khi số lượng đặc trưng lớn hoặc dữ liệu có nhiễu, mô hình dễ bị overfitting. Overfitting xảy ra khi mô hình học quá tốt trên dữ liệu huấn luyện nhưng dự đoán kém trên dữ liệu mới.
Regularization là phương pháp thêm vào hàm mất mát một thành phần phạt nhằm hạn chế độ lớn của trọng số, giúp mô hình tổng quát hóa tốt hơn.
Hàm mất mát tổng quát của Regularization:

$$J(w) = Loss + \lambda \cdot Regularization$$

Trong đó:

- *Loss* là hàm mất mát ban đầu
- λ là hệ số điều chỉnh mức độ Regularization
- *Regularization* là thành phần phạt

Khi λ càng lớn, mô hình càng bị phạt mạnh, trọng số càng nhỏ.

1.4.1 Ridge Regression

Ridge Regression là phương pháp Regularization sử dụng chuẩn L2 để phạt các trọng số lớn.
Hàm mất mát của Ridge Regression:

$$J(w) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^{d} w_j^2$$

Viết dưới dạng ma trận:

$$J(w) = \frac{1}{n}||y - Xw||^2 + \lambda||w||^2$$

Trong đó:

- λ là hệ số điều chỉnh
- $||w||^2$ là chuẩn L2 của vector trọng số

Gradient của Ridge Regression:

$$\nabla J(w) = \frac{2}{n}X^T(Xw - y) + 2\lambda w$$

Cập nhật Gradient Descent:

$$w = w - \alpha\left(\frac{2}{n}X^T(Xw - y) + 2\lambda w\right)$$

Đặc điểm của Ridge Regression

- Làm giảm độ lớn của trọng số
- Không đưa trọng số về đúng bằng 0
- Giữ lại tất cả đặc trưng
- Giảm overfitting hiệu quả

Ridge Regression phù hợp khi các đặc trưng có tương quan với nhau.

1.4.2 Lasso Regression

Lasso Regression là phương pháp Regularization sử dụng chuẩn L1 để phạt trọng số.
Hàm mất mát của Lasso Regression:

$$J(w) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^{d} |w_j|$$

Viết dưới dạng vector:

$$J(w) = \frac{1}{n}||y - Xw||^2 + \lambda ||w||_1$$

Trong đó:

$$||w||_1 = \sum |w_i|$$

Gradient của Lasso Regression:

$$\nabla J(w) = \frac{2}{n}X^T(Xw - y) + \lambda sign(w)$$

Trong đó:

$$sign(w) = \begin{cases} 1 & w > 0 \\ 0 & w = 0 \\ -1 & w < 0 \end{cases}$$

Cập nhật Gradient Descent:

$$w = w - \alpha \left(\frac{2}{n}X^T(Xw - y) + \lambda sign(w)\right)$$

Đặc điểm của Lasso Regression

- Có thể đưa trọng số về 0
- Thực hiện chọn đặc trưng tự động
- Giảm số lượng đặc trưng
- Tăng khả năng giải thích mô hình

Lasso Regression phù hợp khi dữ liệu có nhiều đặc trưng không quan trọng.

1.4.3 So sánh Ridge và Lasso

Tiêu chí	Ridge	Lasso
Chuẩn phạt	L2	L1
Đưa trọng số về 0	Không	Có
Chọn đặc trưng	Không	Có
Giảm overfitting	Tốt	Tốt

1.5 Principal Component Analysis (PCA)

Principal Component Analysis (PCA) là phương pháp giảm chiều dữ liệu bằng cách tìm các trục mới sao cho giữ lại nhiều phương sai nhất của dữ liệu. PCA giúp giảm số lượng đặc trưng nhưng vẫn giữ được thông tin quan trọng.

1.5.1 Chuẩn hóa dữ liệu

Trước khi thực hiện PCA, dữ liệu cần được chuẩn hóa để các đặc trưng có cùng thang đo. Trung bình của mỗi đặc trưng được tính như sau:

$$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Sau đó dữ liệu được chuẩn hóa:

$$Z = X - \mu$$

Trong đó:

- X là ma trận dữ liệu ban đầu
- μ là vector trung bình của từng đặc trưng
- Z là dữ liệu sau khi chuẩn hóa

Sau bước này, dữ liệu sẽ có trung bình bằng 0.

1.5.2 Ma trận hiệp phương sai

Sau khi chuẩn hóa dữ liệu, ma trận hiệp phương sai được tính như sau:

$$C = \frac{1}{n}Z^T Z$$

Trong đó:

- C là ma trận hiệp phương sai
- Z là dữ liệu đã chuẩn hóa

Ma trận hiệp phương sai biểu diễn mức độ tương quan giữa các đặc trưng.
Nếu giá trị lớn, hai đặc trưng có tương quan mạnh. Nếu giá trị gần 0, hai đặc trưng ít tương quan.

1.5.3 Eigen Decomposition

Sau khi có ma trận hiệp phương sai, ta thực hiện phân rã eigen:

$$Cv = \lambda v$$

Trong đó:

- v là eigenvector
- λ là eigenvalue

Eigenvector biểu diễn hướng chính của dữ liệu. Eigenvalue biểu diễn mức độ quan trọng của hướng đó.
Các eigenvector được sắp xếp theo eigenvalue giảm dần để chọn các thành phần quan trọng nhất.

1.5.4 Explained Variance Ratio

Để xác định mức độ thông tin giữ lại, sử dụng explained variance ratio:

$$ratio = \frac{\lambda_i}{\sum \lambda}$$

Trong đó:

- λ_i là eigenvalue thứ i
- $\sum \lambda$ là tổng tất cả eigenvalue

Giá trị này cho biết phần trăm phương sai được giữ lại bởi mỗi thành phần chính.
Tổng phương sai tích lũy:

$$cumulative = \sum_{i=1}^{k} ratio_i$$

Số chiều k được chọn sao cho giữ lại phần lớn phương sai của dữ liệu.

1.5.5 Chiếu dữ liệu

Sau khi chọn k eigenvector quan trọng nhất, ta tạo ma trận:

$$W = \begin{bmatrix} v_1 & v_2 & ... & v_k \end{bmatrix}$$

Dữ liệu được chiếu sang không gian mới:

$$X_{PCA} = ZW$$

Trong đó:

- Z là dữ liệu đã chuẩn hóa
- W là ma trận eigenvector
- X_{PCA} là dữ liệu sau khi giảm chiều

Sau khi chiếu, dữ liệu có số chiều nhỏ hơn nhưng vẫn giữ được thông tin quan trọng nhất.

1.5.6 Ý nghĩa của PCA

- Giảm số lượng đặc trưng
- Giảm nhiễu dữ liệu
- Giảm overfitting
- Tăng tốc độ huấn luyện mô hình
- Giữ lại thông tin quan trọng nhất

Chương 2

Phân tích và Khám phá Dữ liệu

2.1 Tổng quan về dữ liệu

Bộ dữ liệu được sử dụng để huấn luyện mô hình được cung cấp trong file `train.csv`. Dữ liệu sau đó được tách thành hai phần:
Bộ dữ liệu được sử dụng để huấn luyện mô hình được cung cấp trong file `train.csv`. Dữ liệu sau đó được tách thành hai phần:

- X_train_full: Tập đặc trưng đầu vào
- y_train_full: Biến mục tiêu (SalePrice)

Bộ dữ liệu bao gồm:

- 1460 mẫu dữ liệu
- 79 đặc trưng đầu vào
  - 43 đặc trưng kiểu object (categorical)
  - 36 đặc trưng kiểu number (numerical)

Các đặc trưng gồm:

- **MSSubClass**: Loại hình nhà ở tham gia giao dịch
- **MSZoning**: Phân loại quy hoạch khu đất
- **LotFrontage**: Chiều dài tiếp giáp đường của lô đất
- **LotArea**: Diện tích lô đất
- **Street**: Loại đường tiếp cận lô đất
- **Alley**: Loại hẻm tiếp cận lô đất
- **LotShape**: Hình dạng lô đất
- **LandContour**: Độ bằng phẳng của lô đất
- **Utilities**: Loại tiện ích công cộng
- **LotConfig**: Cấu hình lô đất

- **LandSlope**: Độ dốc của lô đất
- **Neighborhood**: Vị trí khu dân cư
- **Condition1**: Điều kiện môi trường xung quanh chính
- **Condition2**: Điều kiện môi trường xung quanh phụ
- **BldgType**: Loại công trình nhà ở
- **HouseStyle**: Kiểu dáng nhà
- **OverallQual**: Đánh giá tổng thể chất lượng nhà
- **OverallCond**: Đánh giá tổng thể tình trạng nhà
- **YearBuilt**: Năm xây dựng
- **YearRemodAdd**: Năm cải tạo
- **RoofStyle**: Kiểu mái nhà
- **RoofMatl**: Vật liệu mái
- **Exterior1st**: Lớp phủ bên ngoài chính
- **Exterior2nd**: Lớp phủ bên ngoài thứ hai
- **MasVnrType**: Loại ốp đá/gạch
- **MasVnrArea**: Diện tích ốp đá/gạch
- **ExterQual**: Chất lượng vật liệu bên ngoài
- **ExterCond**: Tình trạng vật liệu bên ngoài
- **Foundation**: Loại móng nhà
- **BsmtQual**: Chất lượng tầng hầm
- **BsmtCond**: Tình trạng tầng hầm
- **BsmtExposure**: Mức độ lộ thiên tầng hầm
- **BsmtFinType1**: Loại hoàn thiện tầng hầm 1
- **BsmtFinSF1**: Diện tích tầng hầm hoàn thiện 1
- **BsmtFinType2**: Loại hoàn thiện tầng hầm 2
- **BsmtFinSF2**: Diện tích tầng hầm hoàn thiện 2
- **BsmtUnfSF**: Diện tích tầng hầm chưa hoàn thiện
- **TotalBsmtSF**: Tổng diện tích tầng hầm
- **Heating**: Hệ thống sưởi
- **HeatingQC**: Chất lượng hệ thống sưởi

- **CentralAir**: Điều hòa trung tâm
- **Electrical**: Hệ thống điện
- **1stFlrSF**: Diện tích tầng 1
- **2ndFlrSF**: Diện tích tầng 2
- **LowQualFinSF**: Diện tích hoàn thiện chất lượng thấp
- **GrLivArea**: Diện tích sinh hoạt trên mặt đất
- **BsmtFullBath**: Phòng tắm đầy đủ tầng hầm
- **BsmtHalfBath**: Phòng tắm nửa tầng hầm
- **FullBath**: Phòng tắm đầy đủ
- **HalfBath**: Phòng tắm nửa
- **BedroomAbvGr**: Số phòng ngủ
- **KitchenAbvGr**: Số phòng bếp
- **KitchenQual**: Chất lượng phòng bếp
- **TotRmsAbvGrd**: Tổng số phòng trên mặt đất
- **Functional**: Mức độ chức năng nhà
- **Fireplaces**: Số lượng lò sưởi
- **FireplaceQu**: Chất lượng lò sưởi
- **GarageType**: Loại nhà để xe
- **GarageYrBlt**: Năm xây garage
- **GarageFinish**: Mức độ hoàn thiện garage
- **GarageCars**: Sức chứa garage
- **GarageArea**: Diện tích garage
- **GarageQual**: Chất lượng garage
- **GarageCond**: Tình trạng garage
- **PavedDrive**: Đường lái xe trải nhựa
- **WoodDeckSF**: Diện tích sàn gỗ ngoài trời
- **OpenPorchSF**: Diện tích hiên mở
- **EnclosedPorch**: Diện tích hiên kín
- **3SsnPorch**: Diện tích hiên 3 mùa
- **ScreenPorch**: Diện tích hiên có lưới chắn

- **PoolArea**: Diện tích hồ bơi
- **PoolQC**: Chất lượng hồ bơi
- **Fence**: Chất lượng hàng rào
- **MiscFeature**: Đặc điểm linh tinh
- **MiscVal**: Giá trị đặc điểm linh tinh
- **MoSold**: Tháng bán
- **YrSold**: Năm bán
- **SaleType**: Loại giao dịch bán
- **SaleCondition**: Điều kiện giao dịch bán

2.1.1 Hiển thị dữ liệu ban đầu

Tiến hành hiển thị 36 dòng đầu tiên của dữ liệu:

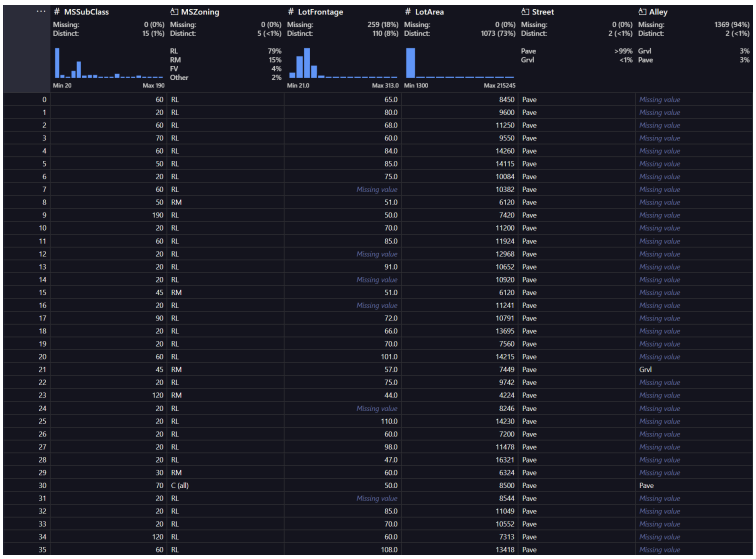

	# MSSubClass	MSZoning	# LotFrontage	# LotArea	Street	Alley
	Missing: 0 (0%)	Missing: 0 (0%)	Missing: 259 (18%)	Missing: 0 (0%)	Missing: 0 (0%)	Missing: 1369 (94%)
	Distinct: 15 (1%)	Distinct: 5 (<1%)	Distinct: 110 (8%)	Distinct: 1073 (73%)	Distinct: 2 (<1%)	Distinct: 2 (<1%)
	Min 20 Max 190	RL 79% RM 15% FV 4% Other 2%	Min 21.0 Max 313.0	Min 1300 Max 215245	Pave >99% Grvl <1%	Grvl 3% Pave 3%
0	60	RL	65.0	8450	Pave	Missing value
1	20	RL	80.0	9600	Pave	Missing value
2	60	RL	68.0	11250	Pave	Missing value
3	70	RL	60.0	9550	Pave	Missing value
4	60	RL	84.0	14260	Pave	Missing value
5	50	RL	85.0	14115	Pave	Missing value
6	20	RL	75.0	10084	Pave	Missing value
7	60	RL	Missing value	10382	Pave	Missing value
8	50	RM	51.0	6120	Pave	Missing value
9	190	RL	50.0	7420	Pave	Missing value
10	20	RL	70.0	11200	Pave	Missing value
11	60	RL	85.0	11924	Pave	Missing value
12	20	RL	Missing value	12968	Pave	Missing value
13	20	RL	91.0	10652	Pave	Missing value
14	20	RL	Missing value	10920	Pave	Missing value
15	45	RM	51.0	6120	Pave	Missing value
16	20	RL	Missing value	11241	Pave	Missing value
17	90	RL	72.0	10791	Pave	Missing value
18	20	RL	66.0	13695	Pave	Missing value
19	20	RL	70.0	7560	Pave	Missing value
20	60	RL	101.0	14215	Pave	Missing value
21	45	RM	57.0	7449	Pave	Grvl
22	20	RL	75.0	9742	Pave	Missing value
23	120	RM	44.0	4224	Pave	Missing value
24	20	RL	Missing value	8246	Pave	Missing value
25	20	RL	110.0	14230	Pave	Missing value
26	20	RL	60.0	7200	Pave	Missing value
27	20	RL	98.0	11478	Pave	Missing value
28	20	RL	47.0	16321	Pave	Missing value
29	30	RM	60.0	6324	Pave	Missing value
30	70	C (all)	50.0	8500	Pave	Pave
31	20	RL	Missing value	8544	Pave	Missing value
32	20	RL	85.0	11049	Pave	Missing value
33	20	RL	70.0	10552	Pave	Missing value
34	120	RL	60.0	7313	Pave	Missing value
35	60	RL	108.0	13418	Pave	Missing value

Hình 2.1: 36 dòng đầu tiên của dữ liệu

Do số lượng đặc trưng lớn nên bảng dữ liệu không thể hiển thị đầy đủ tất cả các cột.

2.1.2 Thống kê mô tả dữ liệu số

Tiến hành sử dụng hàm `describe()` để thống kê mô tả các đặc trưng dạng số.

	MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond
count	1460.000000	1201.000000	1460.000000	1460.000000	1460.000000
mean	56.897260	70.049958	10516.828082	6.099315	5.575342
std	42.300571	24.284752	9981.264932	1.382997	1.112799
min	20.000000	21.000000	1300.000000	1.000000	1.000000
25%	20.000000	59.000000	7553.500000	5.000000	5.000000
50%	50.000000	69.000000	9478.500000	6.000000	5.000000
75%	70.000000	80.000000	11601.500000	7.000000	6.000000
max	190.000000	313.000000	215245.000000	10.000000	9.000000

	YearBuilt	YearRemodAdd	MasVnrArea	BsmtFinSF1	BsmtFinSF2
count	1460.000000	1460.000000	1452.000000	1460.000000	1460.000000
mean	1971.267808	1984.865753	103.685262	443.639726	46.549315
std	30.202904	20.645407	181.066207	456.098091	161.319273
min	1872.000000	1950.000000	0.000000	0.000000	0.000000
25%	1954.000000	1967.000000	0.000000	0.000000	0.000000
50%	1973.000000	1994.000000	0.000000	383.500000	0.000000
75%	2000.000000	2004.000000	166.000000	712.250000	0.000000
max	2010.000000	2010.000000	1600.000000	5644.000000	1474.000000

	GarageArea	WoodDeckSF	OpenPorchSF	EnclosedPorch	3SsnPorch
count	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000
mean	472.980137	94.244521	46.660274	21.954110	3.409589
std	213.804841	125.338794	66.256028	61.119149	29.317331
min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	334.500000	0.000000	0.000000	0.000000	0.000000
50%	480.000000	0.000000	25.000000	0.000000	0.000000
75%	576.000000	168.000000	68.000000	0.000000	0.000000
max	1418.000000	857.000000	547.000000	552.000000	508.000000

	ScreenPorch	PoolArea	MiscVal	MoSold	YrSold
count	1460.000000	1460.000000	1460.000000	1460.000000	1460.000000
mean	15.060959	2.758904	43.489041	6.321918	2007.815753
std	55.757415	40.177307	496.123024	2.703626	1.328095
min	0.000000	0.000000	0.000000	1.000000	2006.000000
25%	0.000000	0.000000	0.000000	5.000000	2007.000000
50%	0.000000	0.000000	0.000000	6.000000	2008.000000
75%	0.000000	0.000000	0.000000	8.000000	2009.000000
max	480.000000	738.000000	15500.000000	12.000000	2010.000000

Hình 2.2: Thống kê mô tả các đặc trưng số

Thống kê mô tả bao gồm các đại lượng sau:

- Mean: Giá trị trung bình của dữ liệu
- Standard Deviation (Std): Độ lệch chuẩn, phản ánh mức độ phân tán của dữ liệu
- Min: Giá trị nhỏ nhất
- 25% (Q1): Tứ phân vị thứ nhất
- 50% (Median): Trung vị của dữ liệu
- 75% (Q3): Tứ phân vị thứ ba
- Max: Giá trị lớn nhất

Các thống kê này giúp hiểu rõ phân phối dữ liệu, phát hiện giá trị ngoại lai (outliers) và đánh giá mức độ biến thiên của từng đặc trưng.

2.1.3 Thông tin dữ liệu thiếu

Để đánh giá mức độ dữ liệu thiếu, tiến hành kiểm tra số lượng giá trị **NaN** trong từng đặc trưng bằng phương pháp `isnull().sum()`.

```
Các đặc trưng bị thiếu dữ liệu và số lượng null:
PoolQC          1453
MiscFeature     1406
Alley           1369
Fence           1179
MasVnrType       872
FireplaceQu      690
LotFrontage      259
GarageType        81
GarageYrBlt       81
GarageFinish      81
GarageQual        81
GarageCond        81
BsmtFinType2      38
BsmtExposure      38
BsmtFinType1      37
BsmtCond          37
BsmtQual          37
MasVnrArea         8
Electrical         1
```

Hình 2.3: Thống kê dữ liệu thiếu của các đặc trưng

Kết quả cho thấy một số đặc trưng có tỷ lệ dữ liệu thiếu khá lớn, chủ yếu tập trung ở các biến sau:

- **MiscFeature**
- **Alley**
- **PoolQC**
- **Fence**

Nguyên nhân của dữ liệu thiếu trong bộ dữ liệu này chủ yếu không phải do lỗi thu thập dữ liệu, mà do **đặc trưng không tồn tại ở một số ngôi nhà**. Điều này là đặc điểm phổ biến trong bài toán dự đoán giá nhà.
Ví dụ:

- Nếu ngôi nhà **không có garage** thì các đặc trưng như **GarageQual, GarageCond, GarageFinish** sẽ có giá trị **NaN**
- Nếu ngôi nhà **không có tầng hầm** thì các đặc trưng như **BsmtQual, BsmtCond, BsmtExposure** sẽ có giá trị **NaN**
- Nếu ngôi nhà **không có hồ bơi** thì đặc trưng **PoolQC** sẽ có giá trị **NaN**

Do đó, các giá trị thiếu trong trường hợp này mang ý nghĩa **thông tin có cấu trúc** thay vì dữ liệu bị lỗi. Điều này cần được cân nhắc kỹ trong quá trình tiền xử lý dữ liệu để tránh làm mất thông tin quan trọng của mô hình.

2.1.4 Thông tin mở rộng dữ liệu

Để hiểu rõ hơn về đặc điểm của từng thuộc tính, một hàm **get_column_initial_info()** được xây dựng nhằm tổng hợp các thông tin quan trọng của mỗi đặc trưng trong bộ dữ liệu. Hàm này cung cấp các thông tin sau:

- **Description**: Mô tả ý nghĩa của đặc trưng
- **Data Type**: Kiểu dữ liệu của đặc trưng (Numerical hoặc Categorical)
- **Missing Values**: Số lượng giá trị bị thiếu (NaN)
- **Unique Values**: Số lượng giá trị khác nhau của đặc trưng
- **Most Frequent Value**: Giá trị xuất hiện nhiều nhất

Việc tổng hợp các thông tin này giúp đánh giá nhanh đặc điểm của từng biến, từ đó hỗ trợ trong việc:

- Xác định các đặc trưng có dữ liệu thiếu
- Phát hiện các đặc trưng có giá trị lặp lại nhiều
- Nhận diện các biến có số lượng giá trị quá lớn hoặc quá nhỏ
- Lựa chọn phương pháp xử lý dữ liệu phù hợp

	Column Name	Description	Data Type	Number of NaN	Unique Values	Most Frequent Value
0	MSSubClass	Identifies the type of dwelling involved in the sale	int64	0	15	20
1	MSZoning	Identifies the general zoning classification of the sale	object	0	5	RL
2	LotFrontage	Linear feet of street connected to property	float64	259	110	60.0
3	LotArea	Lot size in square feet	int64	0	1073	7200
4	Street	Type of road access to property	object	0	2	Pave
5	Alley	Type of alley access to property	object	1369	2	Grvl
6	LotShape	General shape of property	object	0	4	Reg
7	LandContour	Flatness of the property	object	0	4	Lvl
8	Utilities	Type of utilities available	object	0	2	AllPub
9	LotConfig	Lot configuration	object	0	5	Inside
10	LandSlope	Slope of property	object	0	3	Gtl
11	Neighborhood	Physical locations within Ames city limits	object	0	25	NAmes
12	Condition1	Proximity to various conditions	object	0	9	Norm
13	Condition2	Proximity to various conditions (if more than one is present)	object	0	8	Norm
14	BldgType	Type of dwelling	object	0	5	1Fam
15	HouseStyle	Style of dwelling	object	0	8	1Story
16	OverallQual	Rates the overall material and finish of the house	int64	0	10	5
17	OverallCond	Rates the overall condition of the house	int64	0	9	5
18	YearBuilt	Original construction date	int64	0	112	2006
19	YearRemodAdd	Remodel date (same as construction date if no remodeling)	int64	0	61	1950
20	RoofStyle	Type of roof	object	0	6	Gable
21	RoofMatl	Roof material	object	0	8	CompShg
22	Exterior1st	Exterior covering on house	object	0	15	VinylSd
23	Exterior2nd	Exterior covering on house (if more than one material)	object	0	16	VinylSd
24	MasVnrType	Masonry veneer type	object	872	3	BrkFace
25	MasVnrArea	Masonry veneer area in square feet	float64	8	327	0.0
26	ExterQual	Evaluates the quality of the material on the exterior	object	0	4	TA
27	ExterCond	Evaluates the present condition of the material on the exterior	object	0	5	TA
28	Foundation	Type of foundation	object	0	6	PConc
29	BsmtQual	Evaluates the height of the basement	object	37	4	TA
30	BsmtCond	Evaluates the general condition of the basement	object	37	4	TA
31	BsmtExposure	Refers to walkout or garden level walls	object	38	4	No
32	BsmtFinType1	Rating of basement finished area	object	37	6	Unf
33	BsmtFinSF1	Type 1 finished square feet	int64	0	637	0
34	BsmtFinType2	Rating of basement finished area (if multiple types)	object	38	6	Unf
35	BsmtFinSF2	Type 2 finished square feet	int64	0	144	0
36	BsmtUnfSF	Unfinished square feet of basement area	int64	0	780	0
37	TotalBsmtSF	Total square feet of basement area	int64	0	721	0
38	Heating	Type of heating	object	0	6	GasA
39	HeatingQC	Heating quality and condition	object	0	5	Ex
40	CentralAir	Central air conditioning	object	0	2	Y
41	Electrical	Electrical system	object	1	5	SBrkr
42	1stFlrSF	First Floor square feet	int64	0	753	864
43	2ndFlrSF	Second floor square feet	int64	0	417	0
44	LowQualFinSF	Low quality finished square feet	int64	0	24	0
45	GrLivArea	Above grade living area square feet	int64	0	861	864
46	BsmtFullBath	Basement full bathrooms	int64	0	4	0
47	BsmtHalfBath	Basement half bathrooms	int64	0	3	0
48	FullBath	Full bathrooms above grade	int64	0	4	2
49	HalfBath	Half baths above grade	int64	0	3	0
50	BedroomAbvGr	Bedrooms above grade	int64	0	8	3
51	KitchenAbvGr	Kitchens above grade	int64	0	4	1
52	KitchenQual	Kitchen quality	object	0	4	TA
53	TotRmsAbvGrd	Total rooms above grade	int64	0	12	6
54	Functional	Home functionality	object	0	7	Typ
55	Fireplaces	Number of fireplaces	int64	0	4	0
56	FireplaceQu	Fireplace quality	object	690	5	Gd
57	GarageType	Garage location	object	81	6	Attchd
58	GarageYrBlt	Year garage was built	float64	81	97	2005.0
59	GarageFinish	Interior finish of the garage	object	81	3	Unf
60	GarageCars	Size of garage in car capacity	int64	0	5	2
61	GarageArea	Size of garage in square feet	int64	0	441	0
62	GarageQual	Garage quality	object	81	5	TA
63	GarageCond	Garage condition	object	81	5	TA
64	PavedDrive	Paved driveway	object	0	3	Y
65	WoodDeckSF	Wood deck area in square feet	int64	0	274	0
66	OpenPorchSF	Open porch area in square feet	int64	0	202	0
67	EnclosedPorch	Enclosed porch area in square feet	int64	0	120	0
68	3SsnPorch	Three season porch area in square feet	int64	0	20	0

Thông qua bảng thông tin mở rộng, có thể nhận thấy bộ dữ liệu bao gồm nhiều đặc trưng dạng phân loại với số lượng giá trị khác nhau, đồng thời một số đặc trưng có tỷ lệ dữ liệu thiếu đáng kể. Điều này cho thấy cần thực hiện các bước tiền xử lý phù hợp trước khi xây dựng mô hình dự đoán.

2.1.5 Nhận xét

Từ kết quả phân tích thống kê mô tả và thông tin mở rộng của bộ dữ liệu, có thể rút ra một số nhận xét quan trọng như sau:

Kích thước và đặc điểm bộ dữ liệu

Bộ dữ liệu bao gồm **1460 quan sát** với **79 đặc trưng đầu vào**, phù hợp với bài toán hồi quy có quy mô trung bình. Các đặc trưng bao gồm cả **dữ liệu số (numerical)** và **dữ liệu phân loại (categorical)**, do đó cần áp dụng các phương pháp xử lý khác nhau trong giai đoạn tiền xử lý dữ liệu.
Số lượng đặc trưng tương đối lớn, đồng thời chứa nhiều thông tin về diện tích, chất lượng xây dựng, tiện ích và vị trí địa lý của ngôi nhà, tạo điều kiện thuận lợi cho việc xây dựng mô hình dự đoán giá nhà.

Dữ liệu thiếu

Một số đặc trưng có tỷ lệ dữ liệu thiếu rất cao, bao gồm:

- **PoolQC** (99.5%)
- **MiscFeature** (96.3%)
- **Alley** (93.8%)
- **Fence** (80.8%)

Các đặc trưng này có thể không đóng góp nhiều thông tin cho mô hình do phần lớn dữ liệu bị thiếu, vì vậy cần xem xét loại bỏ hoặc xử lý phù hợp trong bước tiền xử lý.
Ngoài ra, một số đặc trưng có dữ liệu thiếu do đặc điểm thực tế của ngôi nhà:

- Các đặc trưng liên quan đến tầng hầm như **BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2** thiếu khoảng 37–38 giá trị, tương ứng với các ngôi nhà không có tầng hầm
- Các đặc trưng liên quan đến garage như **GarageType, GarageYrBlt, GarageFinish, GarageQual, GarageCond** thiếu khoảng 81 giá trị, tương ứng với các ngôi nhà không có garage

Đặc biệt, đặc trưng **LotFrontage** thiếu khoảng **259 giá trị** (khoảng 18%), cần được xử lý cẩn thận vì đây là đặc trưng có thể ảnh hưởng đến giá trị ngôi nhà.

Đặc trưng phân loại

Các đặc trưng dạng phân loại có số lượng giá trị khác nhau, phần lớn nằm trong khoảng hợp lý. Tuy nhiên, một số đặc trưng có giá trị chiếm đa số, bao gồm:

- **MSZoning**: RL chiếm phần lớn
- **Street**: Pave chiếm gần như toàn bộ
- **Utilities**: AllPub chiếm gần như toàn bộ
- **SaleType**: WD chiếm tỷ lệ lớn
- **SaleCondition**: Normal chiếm tỷ lệ lớn

Các đặc trưng có phân phối mất cân bằng có thể ảnh hưởng đến khả năng học của mô hình và cần được xem xét trong bước mã hóa dữ liệu.

Kết luận

Từ các phân tích trên, có thể nhận thấy bộ dữ liệu có:

- Nhiều đặc trưng với thông tin đa dạng
- Tồn tại dữ liệu thiếu ở nhiều đặc trưng
- Sự kết hợp giữa dữ liệu số và dữ liệu phân loại
- Một số đặc trưng có phân phối mất cân bằng

Do đó, cần thực hiện các bước tiền xử lý phù hợp như xử lý dữ liệu thiếu, mã hóa biến phân loại và lựa chọn đặc trưng trước khi xây dựng mô hình dự đoán.

2.2 Trực quan hóa dữ liệu

Để hiểu rõ hơn về đặc điểm của bộ dữ liệu, tiến hành trực quan hóa dữ liệu bằng nhiều loại biểu đồ khác nhau. Do số lượng đặc trưng lớn, chỉ một số đặc trưng tiêu biểu được lựa chọn nhằm làm nổi bật các mối quan hệ quan trọng phục vụ cho bài toán dự đoán giá nhà.

2.2.1 Ma trận tương quan các đặc trưng số

Ma trận tương quan được sử dụng để phân tích mức độ liên hệ tuyến tính giữa các đặc trưng số. Việc phân tích tương quan giúp xác định những đặc trưng có ảnh hưởng lớn đến biến mục tiêu **SalePrice**, từ đó hỗ trợ quá trình lựa chọn đặc trưng và xây dựng mô hình.

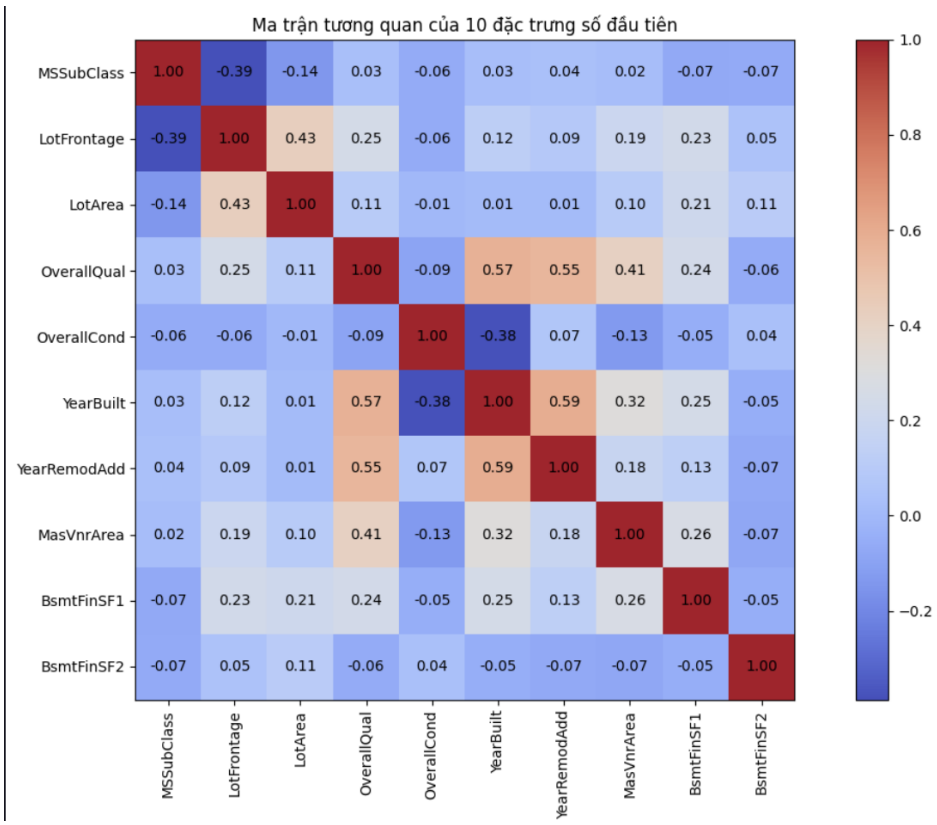

Hình 2.5: Ma trận tương quan giữa 10 đặc trưng số tiêu biểu

Hình trên thể hiện mức độ tương quan giữa các đặc trưng số quan trọng trong bộ dữ liệu. Các giá trị tương quan gần **1** hoặc **-1** thể hiện mối quan hệ tuyến tính mạnh, trong khi các giá trị gần **0** cho thấy mức độ tương quan yếu.

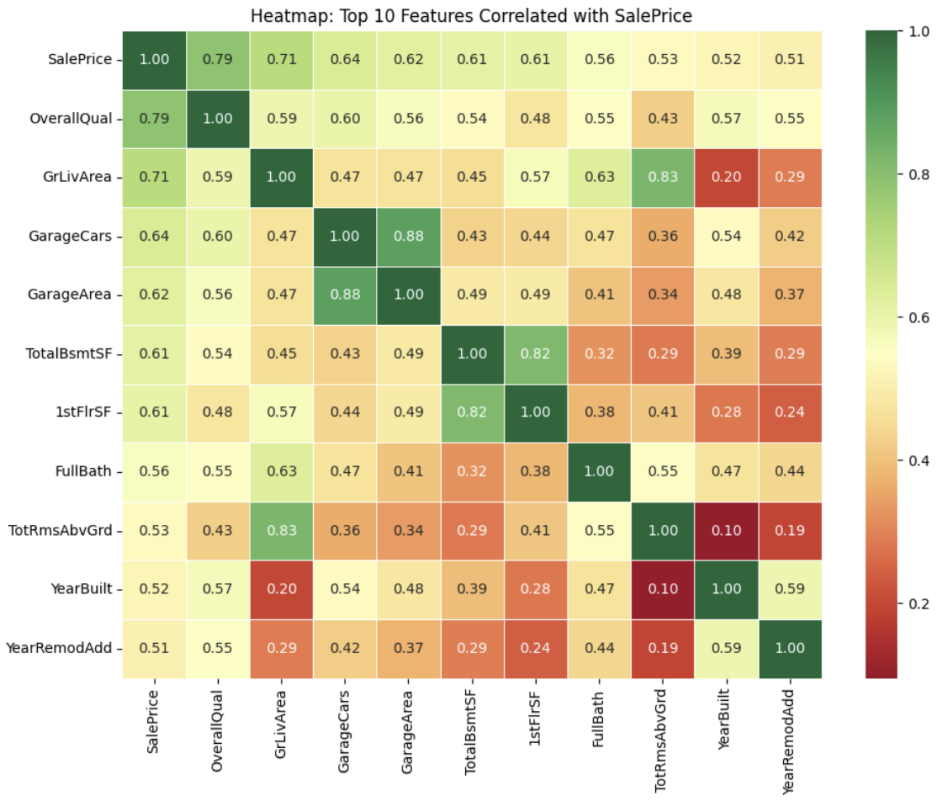

Hình 2.6: Tương quan giữa các đặc trưng số và biến mục tiêu SalePrice

Từ ma trận tương quan với biến mục tiêu **SalePrice**, có thể nhận thấy một số đặc trưng có mức độ tương quan cao, bao gồm:

- **OverallQual**: Chất lượng tổng thể của ngôi nhà
- **GrLivArea**: Diện tích sinh hoạt trên mặt đất
- **GarageCars**: Sức chứa nhà để xe
- **GarageArea**: Diện tích nhà để xe
- **TotalBsmtSF**: Tổng diện tích tầng hầm
- **1stFlrSF**: Diện tích tầng một

Các đặc trưng trên đều có hệ số tương quan dương với **SalePrice**, cho thấy khi các đặc trưng này tăng thì giá nhà có xu hướng tăng theo. Điều này phù hợp với thực tế, vì những ngôi nhà có diện tích lớn, chất lượng tốt hoặc nhiều tiện ích thường có giá trị cao hơn.
Ngoài ra, ma trận tương quan cũng giúp phát hiện một số đặc trưng có mức độ tương quan cao với nhau, ví dụ như **GarageCars** và **GarageArea**, hoặc **TotalBsmtSF** và **1stFlrSF**. Điều này cho thấy khả năng tồn tại hiện tượng **đa cộng tuyến (multicollinearity)**, cần được xem xét trong quá trình xây dựng mô hình hồi quy.

2.2.2 Histogram các đặc trưng số

Để phân tích phân phối của các đặc trưng số, tiến hành vẽ biểu đồ Histogram cho một số biến tiêu biểu trong bộ dữ liệu. Các biểu đồ này giúp quan sát sự phân bố dữ liệu, phát hiện giá trị ngoại lai và đánh giá mức độ lệch của từng đặc trưng.

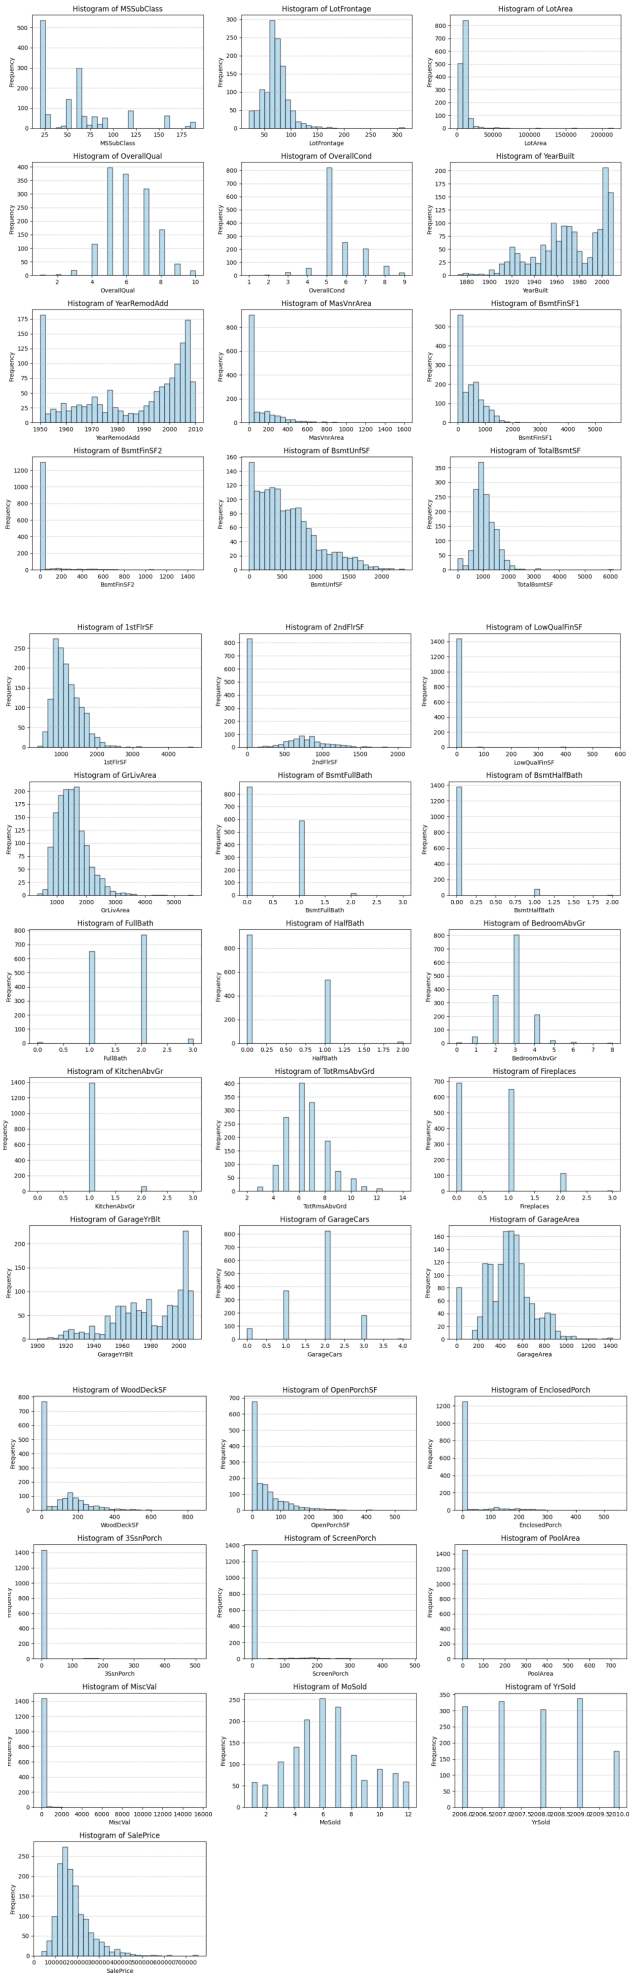

Hình 2.7: Histogram các đặc trưng số

Nhận xét:

- **Nhóm đặc trưng về diện tích** như **1stFlrSF, GrLivArea, TotalBsmtSF** có phân phối **lệch phải**, phần lớn dữ liệu tập trung ở các giá trị trung bình trong khi một số ít ngôi nhà có diện tích rất lớn tạo thành phần đuôi dài.
- **Một số đặc trưng có nhiều giá trị bằng 0** như **2ndFlrSF, LowQualFinSF, PoolArea, MiscVal**. Điều này cho thấy các đặc trưng này chỉ xuất hiện ở một số ít ngôi nhà và có tính chất thưa thớt.
- **Các đặc trưng về chất lượng** như **OverallQual, OverallCond** có phân phối tập trung quanh các giá trị trung bình, cho thấy phần lớn nhà ở có chất lượng từ trung bình đến khá.
- **Một số đặc trưng xuất hiện giá trị ngoại lai (outliers)** như **LotArea, GrLivArea, GarageArea**. Các giá trị này lớn hơn đáng kể so với phần còn lại của dữ liệu.
- **Biến mục tiêu SalePrice** có phân phối lệch phải rõ rệt, với phần lớn giá nhà nằm trong khoảng trung bình và một số ít giá trị rất cao.
- Do nhiều đặc trưng có phân phối lệch phải, **có thể xem xét áp dụng phép biến đổi log (log transform)** nhằm làm giảm độ lệch và cải thiện hiệu suất của mô hình hồi quy.

2.2.3 Biểu đồ phân tán của các đặc trưng số

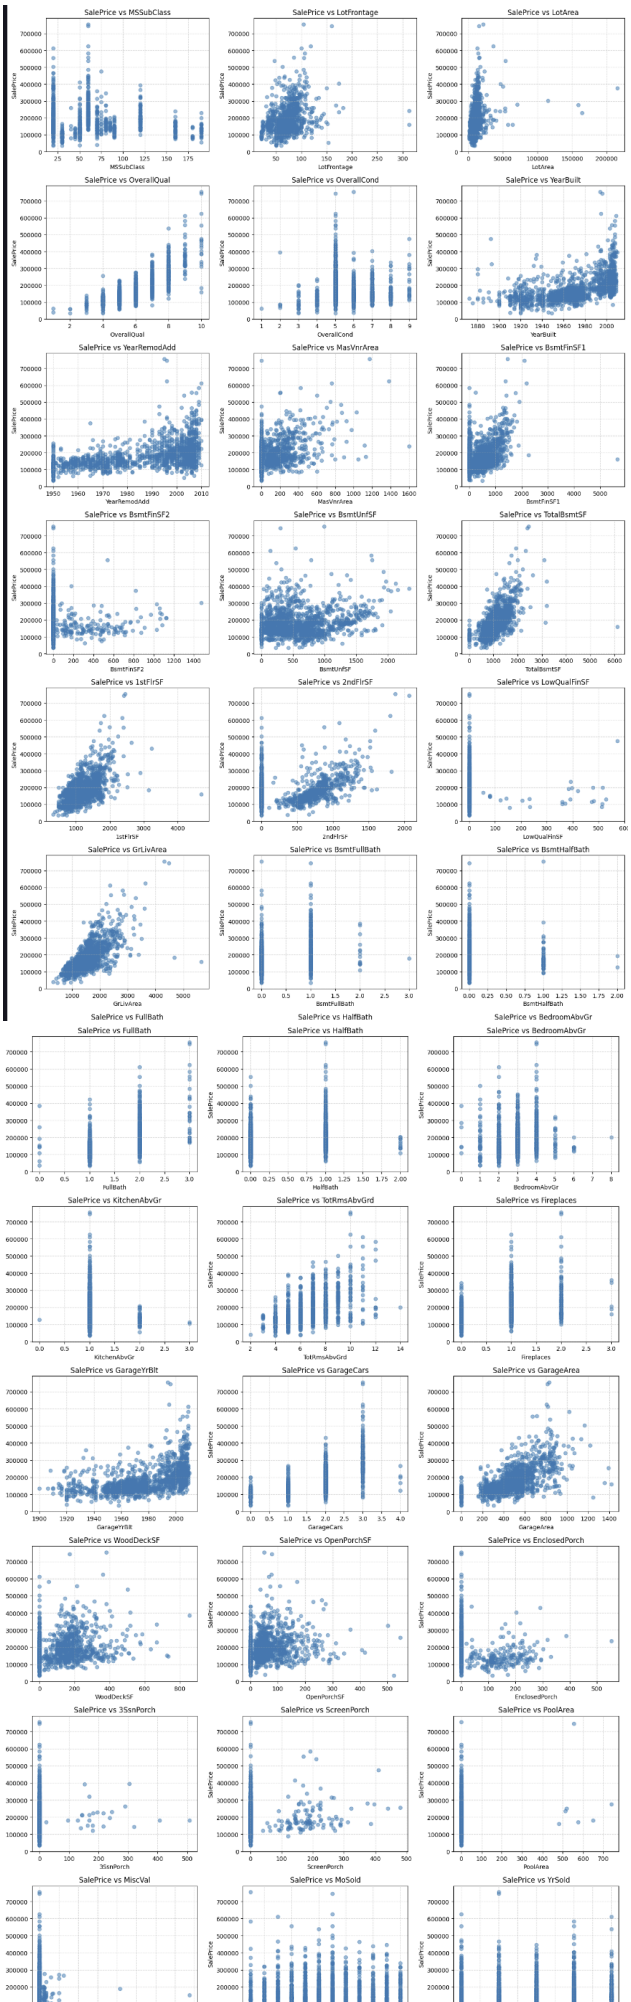

Nhận xét:

- **FullBath, GarageCars, GarageArea, Fireplaces** có tương quan dương khá rõ với SalePrice — giá nhà tăng khi các giá trị này tăng.
- **TotRmsAbvGrd** có tương quan dương nhẹ, số phòng nhiều hơn thường có giá cao hơn nhưng độ phân tán lớn.
- **HalfBath** có ảnh hưởng nhẹ đến giá bán, mối quan hệ không mạnh.
- **BedroomAbvGr** và **KitchenAbvGr** không thể hiện mối quan hệ tuyến tính rõ ràng với SalePrice.
- Các đặc trưng như **WoodDeckSF, OpenPorchSF, EnclosedPorch, ScreenPorch, 3SsnPorch** có nhiều giá trị bằng 0, ảnh hưởng đến SalePrice không đáng kể.
- **PoolArea** có rất ít giá trị khác 0, nhưng những nhà có hồ bơi thường có giá cao.
- **YrSold** không cho thấy xu hướng rõ ràng theo thời gian.
- **GarageYrBlt** có xu hướng dương nhẹ, garage xây mới thường đi kèm giá nhà cao hơn.

2.2.4 Boxplot của các đặc trưng categorical

Để phân tích ảnh hưởng của các đặc trưng dạng phân loại đến giá bán nhà, tiến hành vẽ biểu đồ Boxplot giữa các biến categorical và biến mục tiêu SalePrice. Phương pháp này giúp quan sát sự khác biệt về phân phối giá giữa các nhóm dữ liệu.

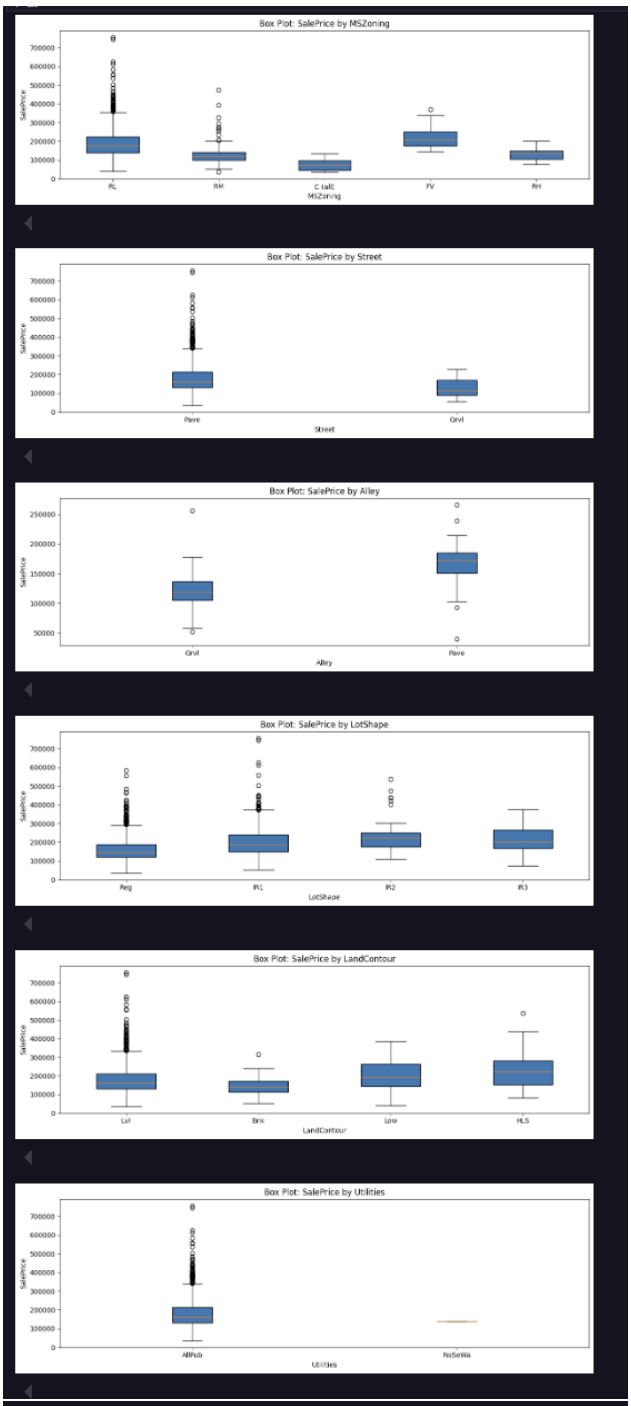
Box Plot: SalePrice by MSZoning
SalePrice
MSZoning
RL
RM
C (all)
FV
RH
Box Plot: SalePrice by Street
SalePrice
Street
Pave
Grvl
Box Plot: SalePrice by Alley
SalePrice
Alley
Grvl
Pave
Box Plot: SalePrice by LotShape
SalePrice
LotShape
Reg
IR1
IR2
IR3
Box Plot: SalePrice by LandContour
SalePrice
LandContour
Lvl
Bnk
Low
HLS
Box Plot: SalePrice by Utilities
SalePrice
Utilities
AllPub
NoSeWa

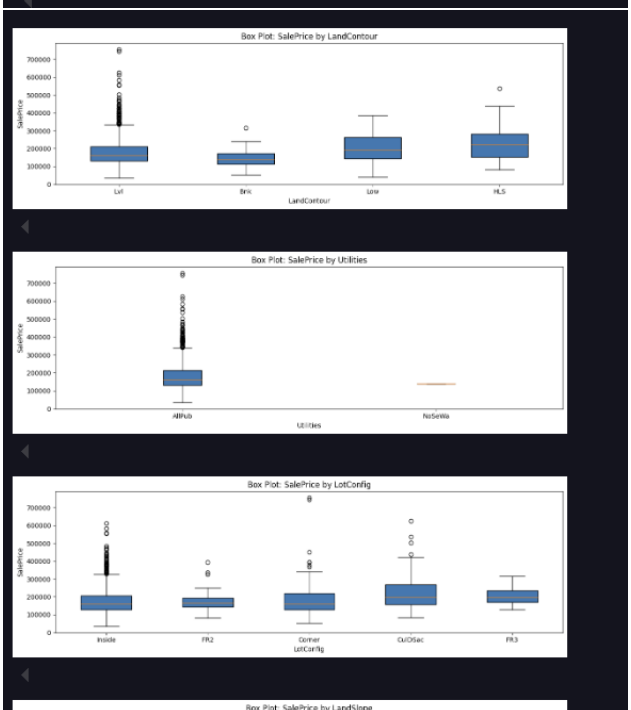
Box Plot: SalePrice by LandContour
SalePrice
LandContour
Lvl
Bnk
Low
HLS
Box Plot: SalePrice by Utilities
SalePrice
Utilities
AllPub
NoSeWa
Box Plot: SalePrice by LotConfig
SalePrice
LotConfig
Inside
FR2
Corner
CulDSac
FR3

Nhận xét:

- **MSZoning:** Khu vực **RL** chiếm đa số với mức giá trải rộng từ trung bình đến cao. **RM** có giá thấp hơn một chút, trong khi **FV** có giá bán cao hơn rõ rệt nhưng số lượng mẫu ít. Các nhóm **C** và **A** có rất ít dữ liệu và biến động lớn. Điều này cho thấy loại quy hoạch có ảnh hưởng đáng kể đến giá nhà.
- **Street:** Phần lớn nhà có đường **Pave**, với giá bán cao và ổn định hơn. Nhóm **Grvl** có ít mẫu và giá thấp hơn. Tuy nhiên do dữ liệu mất cân bằng nên ảnh hưởng không quá mạnh.
- **Alley:** Phần lớn nhà không có hẻm (**NA**). Nhà có hẻm **Pave** thường có giá cao hơn **Grvl**, nhưng do tỷ lệ thiếu dữ liệu lớn nên đặc trưng này có thể ít ảnh hưởng đến mô hình.
- **LotShape: Reg** chiếm đa số với mức giá ổn định. Các dạng **IR1, IR2, IR3** có xu hướng giá thấp hơn và xuất hiện nhiều outlier. Điều này cho thấy hình dạng đất càng đều thì giá càng cao.
- **LandContour:** Nhóm **Lvl** có giá cao và ổn định nhất. Các nhóm **Bnk**, **HLS** và **Low** có giá thấp hơn và số lượng ít. Điều này cho thấy đất bằng phẳng được ưa chuộng hơn.
- Các đặc trưng về **chất lượng** như **ExterQual, KitchenQual, BsmtQual** cho thấy xu hướng rõ rệt: chất lượng càng cao thì giá bán càng lớn.
- **Neighborhood** có ảnh hưởng mạnh đến giá nhà, một số khu vực có mức giá cao vượt trội so với phần còn lại.
- **GarageType** và **GarageFinish** cho thấy nhà có garage hoàn thiện tốt thường có giá cao hơn.
- Một số đặc trưng categorical có độ phân tán lớn trong từng nhóm, cho thấy giá bán còn phụ thuộc vào nhiều yếu tố khác ngoài biến đang xét.

Kết luận:
Nhìn chung, các đặc trưng categorical về **vị trí, chất lượng xây dựng và điều kiện lô đất** có ảnh hưởng rõ rệt đến SalePrice. Trong khi đó, một số đặc trưng có dữ liệu thưa thớt hoặc mất cân bằng lớp như **Alley, Street** có thể ít đóng góp cho mô hình dự đoán.

Chương 3

Tiền xử lý dữ liệu

Các bước tiền xử lý chính được thực hiện bao gồm:

- **Xử lý giá trị khuyết (Missing Values):** Phân tích và xử lý các giá trị bị thiếu bằng các phương pháp phù hợp như thay thế bằng giá trị trung bình, trung vị, mode hoặc loại bỏ nếu cần thiết.
- **Xử lý giá trị ngoại lai (Outliers):** Phát hiện và xử lý các giá trị bất thường nhằm giảm ảnh hưởng tiêu cực đến quá trình huấn luyện mô hình.
- **Mã hóa biến phân loại (Categorical Encoding):** Chuyển đổi các đặc trưng dạng phân loại sang dạng số bằng các phương pháp như Label Encoding hoặc One-Hot Encoding.
- **Biến đổi đặc trưng (Feature Transformation):** Áp dụng các phép biến đổi như log transform hoặc normalization để cải thiện phân phối dữ liệu.
- **Tạo đặc trưng mới (Feature Creation):** Kết hợp hoặc xây dựng các đặc trưng mới nhằm tăng khả năng biểu diễn của dữ liệu.
- **Chuẩn hóa dữ liệu (Scaling):** Chuẩn hóa các đặc trưng số về cùng thang đo nhằm giúp mô hình hội tụ nhanh hơn và ổn định hơn.
- **Giảm chiều dữ liệu (Dimensionality Reduction - nếu có):** Loại bỏ các đặc trưng ít quan trọng hoặc tương quan cao nhằm giảm độ phức tạp của mô hình.

3.1 Xử lý giá trị khuyết (Missing Values Handling)

3.1.1 Mô tả vấn đề

Dựa trên kết quả phân tích dữ liệu thăm dò (EDA) ở Chương 2, bộ dữ liệu chứa nhiều đặc trưng có giá trị khuyết với tỷ lệ khác nhau. Một số cột có tỷ lệ thiếu rất lớn như **Alley, PoolQC, Fence, MiscFeature**, trong khi một số đặc trưng khác chỉ thiếu một lượng nhỏ dữ liệu như **GarageType, BsmtQual, MasVnrArea**.
Các giá trị thiếu trong bộ dữ liệu này không hoàn toàn là lỗi thu thập dữ liệu, mà nhiều trường hợp mang ý nghĩa thực tế như không có garage, không có tầng hầm hoặc không có hồ bơi. Vì vậy, việc xử lý giá trị khuyết cần dựa trên **kiến thức miền (domain knowledge)** kết hợp với các phương pháp thống kê phù hợp.

3.1.2 Phương pháp tiếp cận

Các giá trị khuyết được xử lý theo từng nhóm đặc trưng nhằm đảm bảo giữ lại tối đa thông tin hữu ích và tránh gây sai lệch cho mô hình. Chi tiết xử lý như sau:
1. Nhóm cột diện tích và số lượng
Các đặc trưng:

- TotalBsmtSF
- GarageArea
- GarageCars
- MasVnrArea

Các cột này nếu bị thiếu thường có nghĩa là không tồn tại đặc trưng đó (ví dụ: không có tầng hầm hoặc không có garage). Vì vậy, các giá trị khuyết được thay thế bằng **0**.
2. Nhóm đặc trưng tầng hầm (Basement)
Các đặc trưng:

- BsmtQual
- BsmtCond
- BsmtExposure
- BsmtFinType1
- BsmtFinType2

Phương pháp xử lý:

- Nếu **TotalBsmtSF = 0** thì điền giá trị **'None'** (không có tầng hầm)
- Nếu vẫn còn giá trị thiếu, điền bằng **Mode** (giá trị xuất hiện nhiều nhất) từ tập huấn luyện

3. Nhóm đặc trưng Garage
Các đặc trưng:

- GarageType
- GarageFinish
- GarageQual
- GarageCond

Phương pháp xử lý:

- Nếu **GarageArea = 0** hoặc **GarageCars = 0** thì điền **'None'**
- Nếu vẫn còn giá trị thiếu, điền bằng **Mode** từ tập huấn luyện

4. Năm xây garage

- GarageYrBlt

Đặc trưng này được điền bằng **YearBuilt** vì trong nhiều trường hợp garage được xây cùng thời điểm với ngôi nhà.
5. Nhóm đặc trưng thiếu mang ý nghĩa "không tồn tại"
Các đặc trưng:

- Alley
- FireplaceQu
- PoolQC
- Fence
- MiscFeature

Các cột này được điền bằng giá trị **'None'** vì giá trị thiếu thể hiện đặc trưng không tồn tại.
6. Các đặc trưng categorical còn lại
Các cột phân loại khác có giá trị thiếu sẽ được điền bằng **Mode** (giá trị xuất hiện nhiều nhất) từ tập huấn luyện.
7. Các đặc trưng numeric còn lại
Các cột số còn lại được điền bằng **Median** thay vì Mean nhằm giảm ảnh hưởng của các giá trị ngoại lai.

3.1.3 Lưu ý quan trọng

Việc tính toán **Mode** và **Median** chỉ được thực hiện trên **tập huấn luyện (fit)** và sau đó áp dụng cho cả tập huấn luyện và tập kiểm tra (transform). Cách làm này giúp tránh hiện tượng **data leakage**, đảm bảo tính khách quan trong quá trình huấn luyện và đánh giá mô hình.
Sau bước xử lý này, bộ dữ liệu không còn giá trị khuyết và sẵn sàng cho các bước tiền xử lý tiếp theo.

3.2 Xử lý ngoại lai

3.2.1 Mô tả vấn đề

Trong bài toán hồi quy tuyến tính, các giá trị ngoại lai (outliers) có thể ảnh hưởng mạnh đến quá trình huấn luyện do mô hình cố gắng tối thiểu hóa sai số bình phương (MSE). Điều này khiến mô hình bị lệch theo các điểm bất thường và làm giảm khả năng dự đoán tổng thể. Vì vậy, việc phát hiện và loại bỏ các điểm ngoại lai là cần thiết nhằm cải thiện độ ổn định và hiệu suất của mô hình.

3.2.2 Phương pháp tiếp cận

Trong nghiên cứu này, phương pháp **IQR (Interquartile Range)** được sử dụng để phát hiện các giá trị ngoại lai. Đây là phương pháp thống kê phổ biến, ít bị ảnh hưởng bởi phân phối lệch và phù hợp với các đặc trưng có phân phối không chuẩn.
Các bước thực hiện:

- Tính giá trị tứ phân vị thứ nhất (**Q1**) và tứ phân vị thứ ba (**Q3**)
- Tính khoảng tứ phân vị: [IQR = Q3 - Q1]
- Xác định ngưỡng dưới và ngưỡng trên:
  $Lower\ bound = Q1 - 1.5 \times IQR$
  $Upper\ bound = Q3 + 1.5 \times IQR$

Các giá trị nằm ngoài khoảng [**Lower bound, Upper bound**] được xem là ngoại lai.
Các cột được lựa chọn để xử lý ngoại lai bao gồm:

- GrLivArea (Diện tích sinh hoạt trên mặt đất)
- TotalSF (Tổng diện tích nhà)
- LotArea (Diện tích lô đất)

Các đặc trưng này được chọn vì có phân phối lệch phải và xuất hiện một số giá trị rất lớn so với phần còn lại của dữ liệu.

3.3 Mã hóa biến phân loại

3.3.1 Mô tả vấn đề

Các mô hình học máy, đặc biệt là hồi quy tuyến tính, chỉ có thể xử lý dữ liệu dạng số. Tuy nhiên, trong bộ dữ liệu tồn tại nhiều đặc trưng dạng chuỗi (object) như chất lượng nhà, loại khu vực, kiểu garage,... Vì vậy, cần chuyển đổi các biến phân loại sang dạng số thông qua các phương pháp mã hóa phù hợp.
Trong nghiên cứu này, hai phương pháp mã hóa được xem xét, trong đó phương pháp mã hóa kết hợp được ưu tiên do giữ được ý nghĩa thứ bậc của dữ liệu và hạn chế tăng số chiều.

3.3.2 Phương pháp 1: Mã hóa kết hợp (Hybrid Encoding)

Phương pháp này kết hợp giữa **Ordinal Encoding** và **One-hot Encoding** tùy theo đặc điểm của từng loại biến.
1. Ordinal Encoding (Mã hóa thứ bậc)
Áp dụng cho các biến có thứ tự tự nhiên như mức chất lượng hoặc điều kiện. Các giá trị được ánh xạ thành số theo thứ tự tăng dần.
Ví dụ:

- Ex → 5
- Gd → 4
- TA → 3
- Fa → 2
- Po → 1
- None → 0

Các cột áp dụng gồm:

- ExterQual
- ExterCond
- BsmtQual
- BsmtCond
- HeatingQC
- KitchenQual
- FireplaceQu
- GarageQual
- GarageCond
- PoolQC
- LotShape
- BsmtExposure
- BsmtFinType1
- BsmtFinType2
- GarageFinish
- Fence
- Utilities

Việc sử dụng mã hóa thứ bậc giúp giữ nguyên mối quan hệ thứ tự giữa các giá trị và phù hợp với các mô hình tuyến tính.
2. One-hot Encoding
Các biến phân loại còn lại không có thứ tự tự nhiên sẽ được mã hóa bằng **One-hot Encoding**. Phương pháp này tạo ra các cột nhị phân (0/1) đại diện cho từng giá trị riêng biệt của biến.
Phương pháp này giúp tránh việc mô hình hiểu sai mối quan hệ thứ tự giữa các giá trị phân loại.

3.3.3 Phương pháp 2: One-hot Encoding toàn bộ (Full One-hot)

Ngoài phương pháp kết hợp, một phương pháp dự phòng là sử dụng **One-hot Encoding** cho toàn bộ các biến categorical. Trong phương pháp này, tất cả các biến phân loại được chuyển thành các cột nhị phân (0/1).
Tuy nhiên, phương pháp này có nhược điểm là làm tăng số chiều dữ liệu đáng kể, có thể gây ra hiện tượng **curse of dimensionality** và làm giảm hiệu suất của mô hình hồi quy tuyến tính. Vì vậy, phương pháp này chỉ được sử dụng để so sánh và đánh giá với phương pháp mã hóa kết hợp.

3.4 Biến đổi đặc trưng

3.4.1 Mô tả vấn đề

Trong nhiều bài toán hồi quy tuyến tính, các đặc trưng có phân phối lệch hoặc mối quan hệ phi tuyến với biến mục tiêu có thể làm giảm hiệu suất mô hình. Do đó, việc biến đổi đặc trưng nhằm đưa dữ liệu về phân phối gần chuẩn và làm rõ mối quan hệ giữa các biến là bước quan trọng để cải thiện độ chính xác của mô hình.

3.4.2 Xử lý độ lệch (Skewness Correction)

Dựa trên kết quả phân tích phân phối dữ liệu ở chương 2, nhiều đặc trưng số có phân phối lệch phải mạnh. Để giảm độ lệch này, tiến hành tính hệ số **skewness** cho từng biến số.
Các bước thực hiện:

- Tính độ lệch (skewness) của tất cả các đặc trưng số.
- Xác định ngưỡng: $|\text{skewthreshold}| = 0.75$
- Với các đặc trưng có: $|\text{skewness}| > 0.75$
- Áp dụng phép biến đổi log để giảm độ lệch: $x' = \log(1 + x)$

Phép biến đổi log giúp giảm ảnh hưởng của các giá trị lớn, làm phân phối dữ liệu cân bằng hơn và cải thiện khả năng học của mô hình tuyến tính.
Các đặc trưng được áp dụng biến đổi bao gồm:

- LotFrontage
- LotArea
- MasVnrArea
- BsmtFinSF1
- BsmtFinSF2
- BsmtUnfSF
- TotalBsmtSF
- 1stFlrSF
- 2ndFlrSF
- LowQualFinSF
- GrLivArea
- WoodDeckSF
- OpenPorchSF
- EnclosedPorch
- 3SsnPorch

- ScreenPorch
- PoolArea
- MiscVal

3.4.3 Tạo đặc trưng đa thức

Ngoài việc biến đổi phân phối, một số đặc trưng có mối quan hệ phi tuyến với biến mục tiêu cũng được mở rộng bằng cách tạo đặc trưng đa thức.
Trong nghiên cứu này, đặc trưng **OverallQual** được tạo thêm biến bình phương: $OverallQual^2$
Việc tạo biến bình phương giúp mô hình nắm bắt tốt hơn mối quan hệ phi tuyến giữa chất lượng tổng thể và giá nhà. Thông thường, khi chất lượng nhà tăng, giá bán không tăng tuyến tính mà có xu hướng tăng mạnh hơn ở các mức chất lượng cao.
Sau bước biến đổi đặc trưng, dữ liệu trở nên phù hợp hơn với mô hình hồi quy tuyến tính và giúp cải thiện khả năng dự đoán trong các bước tiếp theo.

3.5 Tạo đặc trưng mới

3.5.1 Mô tả vấn đề

Việc tạo đặc trưng mới nhằm tổng hợp thông tin từ nhiều đặc trưng gốc để xây dựng các biến có khả năng biểu diễn dữ liệu tốt hơn. Các đặc trưng tổng hợp thường giúp mô hình học được mối quan hệ rõ ràng hơn so với việc sử dụng các biến riêng lẻ, từ đó cải thiện hiệu suất dự đoán.

3.5.2 Các đặc trưng mới được tạo

- **Tổng số phòng tắm (TotalBath)**

  Đặc trưng này kết hợp tất cả các phòng tắm đầy đủ và phòng tắm nửa:

  $$\text{TotalBath} = \text{FullBath} + 0.5 \times \text{HalfBath} + \text{BsmtFullBath} + 0.5 \times \text{BsmtHalfBath}$$

  Việc gộp các phòng tắm giúp phản ánh tốt hơn tiện nghi tổng thể của ngôi nhà.

- **Tổng diện tích sử dụng (TotalSF)**

  Đặc trưng này tổng hợp diện tích tầng hầm và các tầng trên:

  $$\text{TotalSF} = \text{TotalBsmtSF} + \text{1stFlrSF} + \text{2ndFlrSF}$$

  Tổng diện tích thường có tương quan mạnh với giá nhà hơn so với từng diện tích riêng lẻ.

- **Tuổi của ngôi nhà (HouseAge)**

  Đặc trưng này thể hiện tuổi của ngôi nhà tại thời điểm bán:

  $$\text{HouseAge} = \text{YrSold} - \text{YearBuilt}$$

  Nhà càng mới thường có giá trị cao hơn, do đó đặc trưng này có ý nghĩa quan trọng.

- **Thời gian từ lần cải tạo gần nhất (RemodAge)**

  Đặc trưng này phản ánh thời gian kể từ lần cải tạo gần nhất đến khi bán:

$$\text{RemodAge} = \text{YrSold} - \text{YearRemodAdd}$$

  Nhà được cải tạo gần đây thường có giá bán cao hơn.

3.5.3 Lưu ý

Sau khi tạo các đặc trưng tổng hợp, một số cột thành phần được loại bỏ nhằm giảm hiện tượng đa cộng tuyến (multicollinearity), bao gồm:

- FullBath
- HalfBath
- TotalBsmtSF
- 1stFlrSF
- 2ndFlrSF

Việc loại bỏ các đặc trưng này giúp mô hình ổn định hơn và tránh trùng lặp thông tin trong dữ liệu.

3.6 Giảm nhiễu và đa cộng tuyến

3.6.1 Mô tả vấn đề

Sau khi tạo đặc trưng và mã hóa dữ liệu, số lượng đặc trưng có thể tăng đáng kể, đồng thời xuất hiện các biến có thông tin trùng lặp hoặc ít giá trị. Điều này có thể dẫn đến hiện tượng **đa cộng tuyến (multicollinearity)** và gây nhiễu cho mô hình hồi quy tuyến tính.
Do đó, bước giảm nhiễu và đa cộng tuyến được thực hiện nhằm loại bỏ các đặc trưng dư thừa, cải thiện độ ổn định của mô hình và giảm độ phức tạp tính toán.

3.6.2 Các bước thực hiện

- **Loại bỏ các biến mất cân bằng (Imbalanced Features)**

  Các đặc trưng có một giá trị chiếm tỷ lệ quá lớn thường mang ít thông tin hữu ích. Trong nghiên cứu này, các biến có một giá trị chiếm hơn **95%** dữ liệu được loại bỏ.

$$\text{If } \max(\text{valueratio}) > 0.95 \Rightarrow \text{Remove feature}$$

  Việc loại bỏ các biến này giúp giảm nhiễu và tránh làm mô hình học các thông tin không có ý nghĩa.

- **Loại bỏ các biến có tương quan cao**

  Các đặc trưng có hệ số tương quan Pearson quá cao thường mang thông tin trùng lặp, gây ra hiện tượng đa cộng tuyến trong mô hình hồi quy tuyến tính.

  Trong nghiên cứu này, nếu hai biến có hệ số tương quan:

  $$|\text{Pearson correlation}| > 0.9$$

  thì một trong hai biến sẽ được loại bỏ nhằm giảm sự phụ thuộc tuyến tính giữa các đặc trưng.

- **Loại bỏ dummy trap từ One-hot Encoding**

  Sau khi áp dụng One-hot Encoding, một số biến phân loại tạo ra các cột dạng **None** hoặc các nhóm biến có tổng bằng 1. Điều này có thể gây ra hiện tượng **dummy variable trap** trong mô hình tuyến tính.

  Ví dụ:

  - $BsmtCond_None$
  - $GarageQual_None$
  - $GarageCond_None$
  - $FireplaceQu_None$

  Các cột này được loại bỏ để tránh phụ thuộc tuyến tính hoàn hảo giữa các biến.

Sau bước giảm nhiễu và đa cộng tuyến, bộ dữ liệu trở nên gọn hơn, ổn định hơn và phù hợp hơn cho việc huấn luyện mô hình hồi quy tuyến tính.

3.7 Chuẩn hóa dữ liệu

3.7.1 Mô tả vấn đề

Các đặc trưng trong bộ dữ liệu thường có thang đo khác nhau. Ví dụ, diện tích nhà có thể lên đến hàng nghìn, trong khi số phòng chỉ dao động từ 1 đến 10. Điều này có thể khiến các thuật toán tối ưu như **Gradient Descent** hội tụ chậm hoặc không ổn định.
Do đó, việc chuẩn hóa dữ liệu giúp đưa các đặc trưng về cùng một thang đo, cải thiện tốc độ hội tụ và độ ổn định của mô hình.

3.7.2 Phương pháp tiếp cận

1. StandardScaler (Z-score Normalization)
Phương pháp này chuẩn hóa dữ liệu về phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1.
Công thức:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó:

- x : giá trị ban đầu

- μ : giá trị trung bình của đặc trưng
- σ : độ lệch chuẩn của đặc trưng

Phương pháp này phù hợp với các mô hình tuyến tính như:

- Linear Regression
- Ridge Regression
- Lasso Regression
- Gradient Descent

2. Min-Max Scaler
Phương pháp Min-Max Scaling đưa dữ liệu về khoảng xác định, thường là **[0,1]**.
Công thức:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Trong đó:

- x : giá trị ban đầu
- x_{min} : giá trị nhỏ nhất của đặc trưng
- x_{max} : giá trị lớn nhất của đặc trưng

Phương pháp này phù hợp khi:

- Dữ liệu không có nhiều outliers
- Cần giữ nguyên phân phối dữ liệu
- Sử dụng các thuật toán nhạy với thang đo như KNN hoặc Neural Network

Lưu ý
Việc chuẩn hóa dữ liệu được thực hiện theo nguyên tắc:

- Fit scaler trên tập huấn luyện
- Transform trên tập huấn luyện và tập kiểm tra

Điều này giúp tránh hiện tượng **data leakage** và đảm bảo quá trình đánh giá mô hình khách quan.
Sau bước chuẩn hóa dữ liệu, các đặc trưng có cùng thang đo, giúp cải thiện hiệu suất và độ ổn định của mô hình trong quá trình huấn luyện.

3.8 Giảm chiều dữ liệu (Dimensionality Reduction)

3.8.1 Mô tả vấn đề

Sau khi thực hiện One-hot Encoding và tạo đặc trưng mới, số lượng đặc trưng có thể tăng đáng kể, dẫn đến hiện tượng **curse of dimensionality**. Điều này làm tăng chi phí tính toán, gây nhiễu dữ liệu và có thể làm giảm hiệu suất của mô hình.
Do đó, phương pháp **Principal Component Analysis (PCA)** được sử dụng để giảm số chiều dữ liệu, loại bỏ nhiễu và tăng tốc độ huấn luyện mô hình.

3.8.2 Phương pháp PCA

PCA là phương pháp giảm chiều tuyến tính bằng cách biến đổi các đặc trưng ban đầu thành một tập các thành phần chính (principal components) không tương quan với nhau. Các thành phần này được sắp xếp theo thứ tự giảm dần của phương sai.
Các bước thực hiện:

- Chuẩn hóa dữ liệu về cùng thang đo (StandardScaler)
- Tính ma trận hiệp phương sai:

$$C = \frac{1}{n} X^T X$$

- Tính trị riêng (Eigenvalues) và vector riêng (Eigenvectors):

$$Cv = \lambda v$$

- Sắp xếp các eigenvalues theo thứ tự giảm dần
- Chọn k thành phần chính đầu tiên để tạo ma trận chiếu

Dữ liệu sau khi giảm chiều được tính bằng:

$$X_{new} = XW$$

Trong đó:

- X : dữ liệu ban đầu
- W : ma trận các eigenvectors được chọn
- X_{new} : dữ liệu sau khi giảm chiều

Lựa chọn số chiều
Số lượng thành phần chính được lựa chọn dựa trên tổng phương sai giải thích (Explained Variance Ratio):

$$\text{Explained Variance} = \sum_{i=1}^{k} \lambda_i$$

Trong nghiên cứu này, số chiều được chọn sao cho tổng phương sai giải thích đạt **95%**:

$$\sum_{i=1}^{k} \lambda_i \geq 0.95$$

3.8.3 Lưu ý

- PCA chỉ được áp dụng sau bước chuẩn hóa dữ liệu
- PCA được fit trên tập huấn luyện
- Sau đó transform cho cả tập huấn luyện và tập kiểm tra

Việc áp dụng PCA giúp giảm số lượng đặc trưng, loại bỏ nhiễu và cải thiện tốc độ huấn luyện của mô hình hồi quy tuyến tính.

Chương 4

Hồi quy Tuyến tính: Từ Phương trình chuẩn đến Tối ưu hóa Gradient

4.1 Giới thiệu chung

Hồi quy tuyến tính (Linear Regression) là một trong những thuật toán nền tảng nhất của Học máy (Machine Learning). Mục tiêu của mô hình là tìm ra mối quan hệ tuyến tính giữa các biến độc lập X và biến phụ thuộc y thông qua phương trình:

$$\hat{y} = Xw + b \tag{4.1}$$

Trong chương này, chúng ta sẽ đi sâu vào hai cách tiếp cận chính để tối ưu hóa mô hình: giải phương trình giải tích (Ordinary Least Squares) và tối ưu hóa lặp (Gradient Descent). Hai cách tiếp cận này cũng dùng cho bài toán dự đoán giá nhà mà chúng ta chuẩn bị thực hiện.

4.2 Phương pháp Phương trình chuẩn (Ordinary Least Squares)

Phương pháp này tìm trực tiếp bộ tham số $\beta = [b, w]^T$ giúp cực tiểu hóa hàm mất mát bằng cách giải hệ phương trình đạo hàm bằng 0.

4.2.1 Xây dựng Ma trận mở rộng

Để tính toán đồng thời hệ số chặn (intercept) và hệ số góc (coefficients), ta thêm một cột vector đơn vị vào ma trận đặc trưng X:

$$X_b = [1, X] \tag{4.2}$$

4.2.2 Giải thuật Moore-Penrose Pseudoinverse

Trong thực tế, ma trận hiệp phương sai $A = X_b^T X_b$ có thể bị suy biến (không nghịch đảo được). Để đảm bảo tính ổn định toán học, chúng ta sử dụng ma trận giả nghịch đảo (pseudoinverse) ký hiệu là A^+:

$$\beta = (X_b^T X_b)^+ X_b^T y \tag{4.3}$$

Cách tiếp cận này tương ứng với việc sử dụng hàm `np.linalg.pinv` trong lập trình, giúp mô hình hoạt động ổn định ngay cả khi các đặc trưng bị đa cộng tuyến.

4.3 Tối ưu hóa bằng Gradient Descent

Dưới đây là nội dung phần Giới thiệu cho mục Gradient Descent trong tài liệu LaTeX của bạn, được biên soạn dựa trên hình ảnh "nhà leo núi"đầy trực quan mà bạn đã chia sẻ:
Đoạn mã

4.3.1 Giới thiệu: Ý tưởng từ người leo núi

Để hiểu một cách trực quan, kỹ thuật Gradient Descent có thể được ví như một "nhà leo núi"đang tìm đường xuống đáy thung lũng trong một vùng đồi núi nhấp nhô đầy sương mù. Giả sử người đó xuất phát tại một tọa độ ban đầu (x_0, y_0). Nhiệm vụ của người này là thực hiện các bước đi (các lần cập nhật trọng số) để tiến dần về vị trí thấp nhất (điểm cực tiểu của hàm mất mát). Chiến lược của nhà leo núi dựa trên hai quan sát then chốt từ đạo hàm của hàm số $f(x)$:

- **Về hướng đi:** Đường tiếp tuyến tại một điểm bất kỳ có hệ số góc bằng đạo hàm tại điểm đó.
  - Nếu đang ở bên trái điểm cực tiểu, đạo hàm thường có giá trị âm ($f'(x) < 0$), người đó cần tiến sang phải ($\Delta x > 0$).
  - Nếu đang ở bên phải điểm cực tiểu, đạo hàm thường có giá trị dương ($f'(x) > 0$), người đó cần lùi sang trái ($\Delta x < 0$).

  Như vậy, để luôn hướng về phía cực tiểu, bước đi Δx phải luôn **ngược dấu** với đạo hàm.

- **Về độ dài bước đi:** Khi ở càng xa điểm cực tiểu, độ dốc của sườn núi thường càng lớn (giá trị tuyệt đối của đạo hàm lớn). Một cách tự nhiên, bước đi của người đó nên dài hơn khi ở xa và ngắn lại khi đã cận kề đích đến để tránh bước quá đà. Do đó, độ dài bước đi được thiết kế **tỉ lệ thuận** với độ lớn của đạo hàm.

Kết hợp hai yếu tố trên, ta thu được công thức cập nhật trọng số kinh điển:

$$x_{t+1} = x_t - \alpha f'(x_t), \quad \forall t \geq 0 \tag{4.4}$$

Trong đó:

- x_t: Vị trí hiện tại (giá trị trọng số tại thời điểm t).
- α (Learning Rate): Hệ số dương đóng vai trò là "tốc độ học", quyết định độ lớn của sải chân.
- $f'(x_t)$: Đạo hàm tại điểm hiện tại, đóng vai trò là "chiếc la bàn"chỉ hướng dốc.
- Dấu trừ ($-$): Thể hiện nguyên tắc đi ngược hướng dốc để tìm điểm thấp nhất.

Bằng cách lặp lại quy trình này nhiều lần (epochs), mô hình sẽ dần "hội tụ"về đi
Khi tập dữ liệu quá lớn, việc tính toán ma trận nghịch đảo trở nên đắt đỏ. Khi đó, các phương pháp tối ưu hóa dựa trên Gradient là lựa chọn tối ưu.

4.3.2 Mini-batch Gradient Descent: Sự cân bằng giữa tốc độ và độ ổn định

Thay vì tính toán trên toàn bộ dữ liệu (Batch GD) vốn rất chậm, hoặc trên từng mẫu đơn lẻ (Stochastic GD) gây ra sự dao động cực lớn, chúng ta sử dụng phương pháp **Mini-batch Gradient Descent**.
Kỹ thuật này chia tập dữ liệu thành các nhóm nhỏ (*batches*) kích thước k (trong mã nguồn là `batch_size`). Điều này giống như việc nhà leo núi không dừng lại để xem bản đồ sau mỗi bước đi, cũng không đợi đi hết cả ngày mới xem, mà cứ sau một quãng ngắn lại kiểm tra hướng đi một lần. Công thức tính Gradient trung bình cho mỗi nhóm là:

$$\nabla_\theta J(\theta) = \frac{2}{k} X_{batch}^T (X_{batch}\theta - y_{batch}) \tag{4.5}$$

4.3.3 Cơ chế Momentum: Tận dụng quán tính

Trong thực tế, địa hình vùng núi có thể có những hố nhỏ hoặc những đoạn mấp mô khiến nhà leo núi dễ bị kẹt lại. Để giải quyết vấn đề này, cơ chế **Momentum** (Động lượng) được tích hợp bằng cách sử dụng biến vận tốc v.
Ý tưởng là tích lũy các bước đi trước đó để tạo ra "quán tính". Nếu nhà leo núi đang đi đúng hướng dốc, vận tốc sẽ tăng dần giúp vượt qua các điểm cực tiểu địa phương (local minima) và hội tụ nhanh hơn:

$$v_t = \gamma v_{t-1} + \eta \nabla_\theta J(\theta) \tag{4.6}$$

$$\theta = \theta - v_t \tag{4.7}$$

Trong đó γ là hệ số Momentum (thường là 0.9), đóng vai trò như độ ma sát giúp kiểm soát vận tốc, tránh việc "lăn"quá đà.

4.4 Kỹ thuật Điều chuẩn (Regularization): Kiểm soát sự phức tạp

Để ngăn chặn hiện tượng **Overfitting** (khi nhà leo núi cố gắng học thuộc lòng từng viên đá nhỏ trên đường đi thay vì tìm quy luật chung của thung lũng), chúng ta thêm một "thành phần phạt"vào hàm mất mát. Lưu ý rằng trong triển khai thực tế, chúng ta không áp dụng hình phạt lên hệ số chặn (*bias term* θ_0).

4.4.1 L2 Regularization (Ridge Regression)

Thêm bình phương độ lớn của trọng số vào Gradient. Kỹ thuật này ép các trọng số tiến về gần 0 nhưng không triệt tiêu chúng hoàn toàn, giúp mô hình ổn định hơn:

$$\nabla_{reg} = 2\alpha\theta_{no_bias} \tag{4.8}$$

4.4.2 L1 Regularization (Lasso Regression)

Sử dụng giá trị tuyệt đối của trọng số. Đặc điểm của L1 là có khả năng triệt tiêu hoàn toàn các đặc trưng không quan trọng bằng cách đưa trọng số về đúng bằng 0, từ đó thực hiện việc lựa chọn đặc trưng (*Feature Selection*):

$$\nabla_{reg} = \alpha \cdot \text{sgn}(\theta_{no_bias}) \tag{4.9}$$

4.4.3 Elastic Net: Sự kết hợp hoàn hảo

Đây là sự kết hợp giữa L1 và L2 theo tỉ lệ ρ (`l1_ratio`). Nó tận dụng ưu điểm của cả hai: khả năng lựa chọn đặc trưng của Lasso và tính ổn định của Ridge:

$$\nabla_{reg} = \rho\alpha \cdot \text{sgn}(\theta) + (1-\rho)\alpha \cdot 2\theta \tag{4.10}$$

4.5 Ổn định hóa bằng Gradient Clipping

Tại những đoạn dốc dựng đứng, Gradient có thể trở nên cực lớn khiến bước đi nhảy vọt ra khỏi vùng tối ưu (bùng nổ gradient). Kỹ thuật **Gradient Clipping** đóng vai trò như một "dây bảo hiểm", giới hạn độ lớn của bước đi trong một ngưỡng max_norm an toàn:

$$\mathbf{g} = \begin{cases} \mathbf{g}\frac{max_norm}{\|\mathbf{g}\|} & \text{nếu } \|\mathbf{g}\| > max_norm \\ \mathbf{g} & \text{ngược lại} \end{cases} \tag{4.11}$$

4.6 Điều kiện dừng sớm (Early Stopping)

Để tiết kiệm tài nguyên tính toán, quá trình huấn luyện sẽ tự động kết thúc nếu sai số không còn cải thiện đáng kể sau mỗi chu kỳ (*epoch*). Nếu sự thay đổi của Mean Squared Error (MSE) nhỏ hơn ngưỡng tol, mô hình được coi là đã hội tụ:

$$|MSE_{t-1} - MSE_t| < tol \tag{4.12}$$

Chương 5

Phương pháp đánh giá mô hình

5.1 Mean Absolute Error

Mean Absolute Error (MAE) là chỉ số dùng để đánh giá độ sai lệch trung bình giữa giá trị dự đoán và giá trị thực tế.
Công thức MAE:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Trong đó:

- y_i là giá trị thực
- $\hat{y}_i$ là giá trị dự đoán
- n là số lượng mẫu

MAE đo khoảng cách tuyệt đối trung bình giữa dự đoán và thực tế.

5.1.1 Ý nghĩa của MAE

- MAE càng nhỏ, mô hình dự đoán càng chính xác
- MAE = 0 nghĩa là dự đoán hoàn hảo
- MAE lớn nghĩa là sai số dự đoán cao

5.1.2 Lý do lựa chọn MAE để đánh giá

Trong bài toán hồi quy tuyến tính, phương pháp tối ưu phổ biến thường sử dụng hàm mất mát Mean Squared Error (MSE). Khi sử dụng phương trình chính tắc (Ordinary Least Squares), nghiệm tối ưu thu được là nghiệm tối thiểu hóa MSE.
Tuy nhiên, mặc dù mô hình được huấn luyện bằng MSE, việc đánh giá mô hình có thể sử dụng MAE. Điều này được giải thích bởi các lý do sau:

- MAE và MSE có mối tương quan với nhau, khi MSE giảm thì MAE thường cũng giảm
- MAE dễ hiểu hơn vì thể hiện trực tiếp sai số trung bình
- MAE không bị ảnh hưởng mạnh bởi các giá trị ngoại lai như MSE

Ngoài ra, xét về ý nghĩa thực tế, MAE phản ánh trực tiếp mức độ sai lệch trung bình của dự đoán. Trong bài toán dự đoán giá nhà, người sử dụng thường quan tâm đến sai số tuyệt đối trung bình, ví dụ sai lệch trung bình bao nhiêu đô la, thay vì quan tâm đến sai số bình phương như MSE.
Do đó, mặc dù mô hình được huấn luyện dựa trên MSE, việc sử dụng MAE để đánh giá giúp phản ánh trực quan và phù hợp hơn với ý nghĩa thực tế của bài toán.

5.1.3 Ưu điểm của MAE

- Dễ hiểu và dễ diễn giải
- Phản ánh trực tiếp sai số thực tế
- Ít bị ảnh hưởng bởi outlier
- Phù hợp với bài toán dự đoán giá trị liên tục

5.2 Đánh giá mô hình bằng K-Fold Cross Validation

Để đánh giá hiệu suất của mô hình một cách khách quan và tránh hiện tượng "may rủi"khi chia tập dữ liệu, phương pháp K-Fold Cross Validation được áp dụng. Thay vì chỉ chia dữ liệu một lần duy nhất, dữ liệu được chia thành K phần (folds) bằng nhau.

5.2.1 Nguyên lý hoạt động và Ưu điểm

Trong mỗi lần lặp i ($i = 1, \ldots, K$):

- Phần thứ i được giữ lại làm tập kiểm thử (Validation Fold).
- $K - 1$ phần còn lại được dùng để huấn luyện mô hình (Training Folds).
- Chỉ số đánh giá cuối cùng là trung bình cộng của K lần thử nghiệm:

$$\text{MAE}_{avg} = \frac{1}{K} \sum_{i=1}^{K} \text{MAE}_i \tag{5.1}$$

Ưu điểm:

- **Ổn định hơn:** Giảm thiểu sự biến động của sai số do cách chia dữ liệu.
- **Hiệu quả dữ liệu:** Mọi mẫu dữ liệu đều có cơ hội xuất hiện trong cả tập huấn luyện và tập kiểm thử.
- **Phù hợp tập dữ liệu nhỏ:** Giúp tối đa hóa lượng thông tin học được mà vẫn có dữ liệu đánh giá tin cậy.

5.2.2 Triển khai thuật toán và Chống rò rỉ dữ liệu (Data Leakage)

Một trong những sai lầm phổ biến khi thực hiện Cross Validation là thực hiện chuẩn hóa dữ liệu (*Scaling*) trên toàn bộ tập dữ liệu trước khi chia fold. Điều này dẫn đến việc thông tin từ tập kiểm thử bị "lọt"vào tập huấn luyện.
Trong lớp `KFold` đã triển khai, quy trình được thực hiện nghiêm ngặt như sau:

1. **Xáo trộn (Shuffling):** Nếu cấu hình `shuffle=True`, các chỉ số dữ liệu sẽ được hoán vị ngẫu nhiên để triệt tiêu các quy luật sắp xếp vô tình trong file dữ liệu gốc.

2. **Chuẩn hóa cục bộ (Standard Scaling):** Với mỗi fold, `StandardScaler` chỉ được `fit` trên tập huấn luyện của fold đó và sau đó mới dùng để `transform` cho cả tập huấn luyện và tập kiểm thử.

5.2.3 Tích hợp các tùy chọn tối ưu hóa đặc trưng

Thuật toán còn hỗ trợ các cơ chế trích xuất và lựa chọn đặc trưng nâng cao trong từng vòng lặp:

- **Tùy chọn 2 - Giảm chiều dữ liệu (PCA):** Sử dụng Principal Component Analysis để giữ lại 99% phương sai của dữ liệu. Việc này giúp loại bỏ nhiễu và giảm độ phức tạp tính toán:
$$X_{reduced} = \text{PCA}(X, \text{variance} = 0.99) \tag{5.2}$$

- **Tùy chọn 3 - Lựa chọn đặc trưng bằng Lasso (L1 Regularization):** Sử dụng mô hình `GradientDescent` với hình phạt $L1$ để xác định các đặc trưng quan trọng. Các đặc trưng có hệ số hồi quy $|\beta_j| < 10^{-4}$ sẽ bị loại bỏ, chỉ giữ lại các biến có tác động thực sự đến mục tiêu y.

5.2.4 Đánh giá hiệu suất

Kết quả cuối cùng thu được là giá trị Sai số tuyệt đối trung bình (Mean Absolute Error - MAE). Việc sử dụng MAE trong K-Fold cho phép chúng ta hiểu được sai lệch trung bình của mô hình trên đơn vị thực tế của biến mục tiêu, đồng thời đảm bảo rằng con số này có tính tổng quát cao cho các dữ liệu mới chưa từng thấy.

Chương 6

Kết quả thực nghiệm

Trình bày kết quả thực nghiệm của các mô hình hồi quy tuyến tính sau khi thực hiện các bước tiền xử lý và xây dựng đặc trưng ở các chương trước. Các thí nghiệm được thiết kế nhằm đáp ứng các yêu cầu tại mục 3.2 của đề bài, bao gồm sử dụng toàn bộ đặc trưng, lựa chọn đặc trưng tốt nhất và thiết kế đặc trưng mới.

6.1 Mô hình sử dụng toàn bộ đặc trưng (Yêu cầu 2a)

6.1.1 Mô tả

Trong thí nghiệm này, toàn bộ các đặc trưng sau khi tiền xử lý (xử lý missing values, encoding, scaling,...) được đưa vào mô hình hồi quy tuyến tính.
Mô hình được huấn luyện trên tập **train.csv** và đánh giá trên tập **test.csv**.
Phương án này sử dụng pipeline đầy đủ bao gồm:

- Làm sạch dữ liệu (CleanData)
- Mã hóa dữ liệu (EncodeCategorical): sử dụng phương pháp mapping với Ordinal categorical và onehot với Nominal categorical
- Chuẩn hóa dữ liệu (StandardScaler)

6.1.2 Công thức hồi quy

Giả sử mô hình hồi quy tuyến tính có dạng:

$$\text{SalePrice} = w_0 + w_1x_1 + w_2x_2 + \cdots + w_nx_n$$

Sau khi huấn luyện, các hệ số hồi quy thu được (làm tròn 3 chữ số thập phân):

$$
\begin{aligned}
\text{SalePrice} = 180921.196 \\
& - 2040.304 \times \text{MS} + 948.653 \times \text{LO} + 7067.236 \times \text{LO1} \\
& + 9261.766 \times \text{OV} + 6398.107 \times \text{OV1} + 10003.435 \times \text{YE} \\
& + 2236.767 \times \text{YE1} + 2909.146 \times \text{MA} + 7942.870 \times \text{BS} \\
& + 1563.970 \times \text{BS1} - 77.038 \times \text{BS2} + 8755.275 \times \text{TO} \\
& + 5831.378 \times \text{1S} + 14143.916 \times \text{2N} - 1641.933 \times \text{LO2} \\
& + 15887.795 \times \text{GR} + 802.118 \times \text{BS3} - 111.415 \times \text{BS4} \\
& + 2040.105 \times \text{FU} + 952.288 \times \text{HA} - 3055.931 \times \text{BE} \\
& - 2970.997 \times \text{KI} + 2852.913 \times \text{TO1} + 3995.457 \times \text{FI} \\
& - 1070.567 \times \text{GA} + 2738.953 \times \text{GA1} + 4105.896 \times \text{GA2} \\
& + 1947.169 \times \text{WO} + 20.085 \times \text{OP} + 158.704 \times \text{EN} \\
& + 944.598 \times \text{3S} + 2014.049 \times \text{SC} + 27401.904 \times \text{PO} \\
& + 83.579 \times \text{MI} - 1317.378 \times \text{MO} - 781.158 \times \text{YR} \\
& - 2026.780 \times \text{MS1} + 1833.559 \times \text{MS2} - 176.371 \times \text{MS3} \\
& + 398.559 \times \text{MS4} - 997.326 \times \text{MS5} - 1067.473 \times \text{ST} \\
& + 1067.473 \times \text{ST1} + 129.377 \times \text{AL} - 136.712 \times \text{AL1} \\
& + 57.634 \times \text{AL2} - 606.323 \times \text{LO3} + 645.271 \times \text{LO4} \\
& + 413.272 \times \text{LO5} + 300.397 \times \text{LO6} - 512.913 \times \text{LA} \\
& + 905.124 \times \text{LA1} - 2125.792 \times \text{LA2} + 889.536 \times \text{LA3} \\
& + 462.960 \times \text{UT} - 462.960 \times \text{UT1} + 36.084 \times \text{LO7} \\
& + 2098.769 \times \text{LO8} - 1305.350 \times \text{LO9} - 927.456 \times \text{LO10} \\
& - 557.336 \times \text{LO11} + 123.670 \times \text{LA4} + 1624.096 \times \text{LA5} \\
& - 3861.786 \times \text{LA6} + 637.083 \times \text{NE} + 622.145 \times \text{NE1} \\
& + 532.306 \times \text{NE2} + 377.055 \times \text{NE3} - 950.795 \times \text{NE4} \\
& - 841.550 \times \text{NE5} + 3540.403 \times \text{NE6} - 3552.671 \times \text{NE7} \\
& - 795.526 \times \text{NE8} - 676.307 \times \text{NE9} + 171.302 \times \text{NE10} \\
& - 2381.213 \times \text{NE11} - 3644.182 \times \text{NE12} + 1703.814 \times \text{NE13} \\
& - 2215.518 \times \text{NE14} + 5554.310 \times \text{NE15} + 5595.568 \times \text{NE16} \\
& - 1686.718 \times \text{NE17} - 160.136 \times \text{NE18} - 810.638 \times \text{NE19} \\
& + 928.790 \times \text{NE20} + 1175.707 \times \text{NE21} + 6165.862 \times \text{NE22} \\
& - 389.144 \times \text{NE23} + 672.726 \times \text{NE24} - 1924.688 \times \text{CO} \\
& - 830.615 \times \text{CO1} + 1926.331 \times \text{CO2} - 142.905 \times \text{CO3} \\
& + 446.494 \times \text{CO4} - 2244.765 \times \text{CO5} + 315.282 \times \text{CO6} \\
& - 527.386 \times \text{CO7} + 49.088 \times \text{CO8} + 969.901 \times \text{CO9} \\
& + 1301.481 \times \text{CO10} + 1579.362 \times \text{CO11} + 1788.121 \times \text{CO12} \\
& - 7819.465 \times \text{CO13} - 2636.246 \times \text{CO14} + 34.285 \times \text{CO15} \\
& + 868.162 \times \text{CO16} + 2555.965 \times \text{BL} + 340.291 \times \text{BL1} \\
& - 186.860 \times \text{BL2} - 2155.152 \times \text{BL3} - 2226.433 \times \text{BL4} \\
& - 25.172 \times \text{HO} + 1187.389 \times \text{HO1} + 2563.064 \times \text{HO2} \\
& - 1266.120 \times \text{HO3} - 850.593 \times \text{HO4} - 2944.644 \times \text{HO5} \\
& + 113.726 \times \text{HO6} + 558.205 \times \text{HO7} - 922.667 \times \text{RO} \\
& - 73.660 \times \text{RO1} + 215.523 \times \text{RO2} - 181.130 \times \text{RO3} \\
& + 685.465 \times \text{RO4} + 3325.977 \times \text{RO5} - 14967.698 \times \text{RO6} \\
& + 298.241 \times \text{RO7} + 2572.526 \times \text{RO8} + 1754.311 \times \text{RO9}
\end{aligned}
$$

Bảng 6.1: Bảng tra cứu tên đặc trưng và ký hiệu viết tắt (Phần 1/2)

Nhóm 1		Nhóm 2	
Tên gốc (Feature)	**Ký hiệu**	**Tên gốc (Feature)**	**Ký hiệu**
MSSubClass	MS	Neighborhood_Blmngtn	NE
LotFrontage	LO	Neighborhood_Blueste	NE1
LotArea	LO1	Neighborhood_BrDale	NE2
OverallQual	OV	Neighborhood_BrkSide	NE3
OverallCond	OV1	Neighborhood_ClearCr	NE4
YearBuilt	YE	Neighborhood_CollgCr	NE5
YearRemodAdd	YE1	Neighborhood_Crawfor	NE6
MasVnrArea	MA	Neighborhood_Edwards	NE7
BsmtFinSF1	BS	Neighborhood_Gilbert	NE8
BsmtFinSF2	BS1	Neighborhood_IDOTRR	NE9
BsmtUnfSF	BS2	Neighborhood_MeadowV	NE10
TotalBsmtSF	TO	Neighborhood_Mitchel	NE11
1stFlrSF	1S	Neighborhood_NAmes	NE12
2ndFlrSF	2N	Neighborhood_NPkVill	NE13
LowQualFinSF	LO2	Neighborhood_NWAmes	NE14
GrLivArea	GR	Neighborhood_NoRidge	NE15
BsmtFullBath	BS3	Neighborhood_NridgHt	NE16
BsmtHalfBath	BS4	Neighborhood_OldTown	NE17
FullBath	FU	Neighborhood_SWISU	NE18
HalfBath	HA	Neighborhood_Sawyer	NE19
BedroomAbvGr	BE	Neighborhood_SawyerW	NE20
KitchenAbvGr	KI	Neighborhood_Somerst	NE21
TotRmsAbvGrd	TO1	Neighborhood_StoneBr	NE22
Fireplaces	FI	Neighborhood_Timber	NE23
GarageYrBlt	GA	Neighborhood_Veenker	NE24
GarageCars	GA1	Condition1_Artery	CO
GarageArea	GA2	Condition1_Feedr	CO1
WoodDeckSF	WO	Condition1_Norm	CO2
OpenPorchSF	OP	Condition1_PosA	CO3
EnclosedPorch	EN	Condition1_PosN	CO4
3SsnPorch	3S	Condition1_RRAe	CO5
ScreenPorch	SC	Condition1_RRAn	CO6
PoolArea	PO	Condition1_RRNe	CO7
MiscVal	MI	Condition1_RRNn	CO8
MoSold	MO	Condition2_Artery	CO9
YrSold	YR	Condition2_Feedr	CO10

Bảng 6.2: Bảng tra cứu tên đặc trưng và ký hiệu viết tắt (Phần 2/2)

Nhóm 3		Nhóm 4	
Tên gốc (Feature)	**Ký hiệu**	**Tên gốc (Feature)**	**Ký hiệu**
MSZoning_C (all)	MS1	Exterior1st_AsbShng	EX
MSZoning_FV	MS2	Exterior1st_AsphShn	EX1
MSZoning_RH	MS3	Exterior1st_BrkComm	EX2
MSZoning_RL	MS4	Exterior1st_BrkFace	EX3
MSZoning_RM	MS5	Exterior1st_CBlock	EX4
Street_Grvl	ST	Exterior1st_CemntBd	EX5
Street_Pave	ST1	Exterior1st_HdBoard	EX6
Alley_Grvl	AL	Exterior1st_ImStucc	EX7
Alley_None	AL1	Exterior1st_MetalSd	EX8
Alley_Pave	AL2	Exterior1st_Plywood	EX9
LotShape_IR1	LO3	Exterior1st_Stone	EX10
LotShape_IR2	LO4	Exterior1st_Stucco	EX11
LotShape_IR3	LO5	Exterior1st_VinylSd	EX12
LotShape_Reg	LO6	Exterior1st_Wd Sdng	EX13
LandContour_Bnk	LA	Exterior1st_WdShing	EX14
LandContour_HLS	LA1	Exterior2nd_AsbShng	EX15
LandContour_Low	LA2	Exterior2nd_AsphShn	EX16
LandContour_Lvl	LA3	Exterior2nd_Brk Cmn	EX17
Utilities_AllPub	UT	Exterior2nd_BrkFace	EX18
Utilities_NoSeWa	UT1	Exterior2nd_CBlock	EX19
LotConfig_Corner	LO7	Exterior2nd_CmentBd	EX20
LotConfig_CulDSac	LO8	Exterior2nd_HdBoard	EX21
LotConfig_FR2	LO9	Exterior2nd_ImStucc	EX22
LotConfig_FR3	LO10	Exterior2nd_MetalSd	EX23
LotConfig_Inside	LO11	Exterior2nd_Other	EX24
LandSlope_Gtl	LA4	Exterior2nd_Plywood	EX25
LandSlope_Mod	LA5	Exterior2nd_Stone	EX26
LandSlope_Sev	LA6	Exterior2nd_Stucco	EX27
Condition2_Norm	CO11	Exterior2nd_VinylSd	EX28
Condition2_PosA	CO12	Exterior2nd_Wd Sdng	EX29
Condition2_PosN	CO13	Exterior2nd_Wd Shng	EX30
Condition2_RRAe	CO14	MasVnrType_BrkCmn	MA1
Condition2_RRAn	CO15	MasVnrType_BrkFace	MA2
Condition2_RRNn	CO16	MasVnrType_Stone	MA3
BldgType_1Fam	BL	ExterQual_Ex	EX31
BldgType_2fmCon	BL1	ExterQual_Fa	EX32
BldgType_Duplex	BL2	ExterQual_Gd	EX33
BldgType_Twnhs	BL3	ExterQual_TA	EX34
BldgType_TwnhsE	BL4	ExterCond_Ex	EX35
HouseStyle_1.5Fin	HO	ExterCond_Fa	EX36
HouseStyle_1.5Unf	HO1	ExterCond_Gd	EX37
HouseStyle_1Story	HO2	ExterCond_Po	EX38
HouseStyle_2.5Fin	HO3	ExterCond_TA	EX39
HouseStyle_2.5Unf	HO4	Foundation_BrkTil	FO
HouseStyle_2Story	HO5	Foundation_CBlock	FO1
HouseStyle_SFoyer	HO6	Foundation_PConc	FO2
HouseStyle_SLvl	HO7	Foundation_Slab	FO3
RoofStyle_Flat	RO	Foundation_Stone	FO4
RoofStyle_Gable	RO1	Foundation_Wood	FO5
RoofStyle_Gambrel	RO2	BsmtQual_Ex	BS5
RoofStyle_Hip	RO3	BsmtQual_Fa	BS6
RoofStyle_Mansard	RO4	BsmtQual_Gd	BS7
RoofStyle_Shed	RO5	BsmtQual_None	BS8
RoofMatl_ClyTile	RO6	BsmtQual_TA	BS9
RoofMatl_CompShg	RO7	BsmtCond_Fa	BS10
RoofMatl_Membran	RO8	BsmtCond_Gd	BS11
RoofMatl_Metal	RO9	BsmtCond_None	BS12
RoofMatl_Roll	RO10	BsmtCond_Po	BS13
RoofMatl_Tar&Grv	RO11	BsmtCond_TA	BS14
RoofMatl_WdShake	RO12	BsmtExposure_Av	BS15
RoofMatl_WdShngl	RO13	BsmtExposure_Gd	BS16

6.1.3 Kết quả đánh giá

Sai số tuyệt đối trung bình (MAE) trên tập test:

$$MAE = 11169.549$$

Kết quả cho thấy việc sử dụng toàn bộ đặc trưng giúp mô hình tận dụng tối đa thông tin, tuy nhiên có thể xuất hiện hiện tượng dư thừa đặc trưng hoặc đa cộng tuyến.

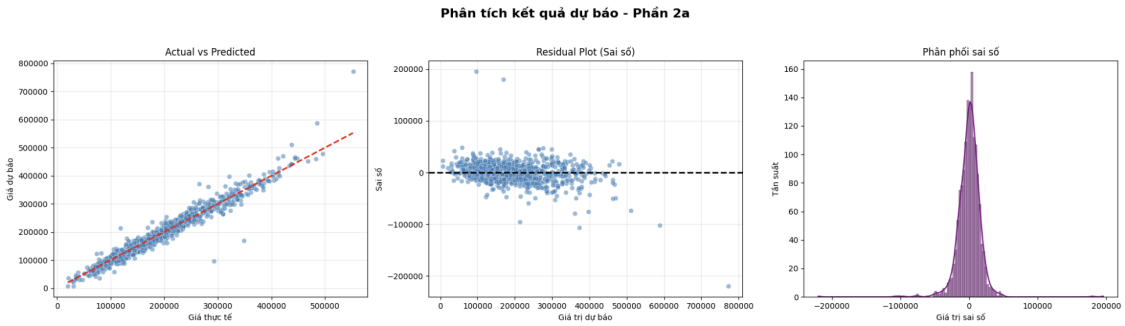

Hình 6.1: Biểu đồ phân tích kết quả dự đoán

6.2 Lựa chọn đặc trưng đơn tốt nhất (Yêu cầu 2b)

6.2.1 Mô tả

Trong phần này, mỗi đặc trưng được sử dụng riêng lẻ để xây dựng mô hình hồi quy tuyến tính nhằm xác định đặc trưng đơn có khả năng dự đoán tốt nhất đối với giá nhà. Phương pháp **K-Fold Cross Validation** được sử dụng để đánh giá hiệu suất của từng đặc trưng.

6.2.2 Các đặc trưng được lựa chọn

Dựa trên phân tích dữ liệu và mức độ tương quan với biến mục tiêu **SalePrice**, năm đặc trưng quan trọng được lựa chọn bao gồm:

- OverallQual (Chất lượng tổng thể)
- GrLivArea (Diện tích sinh hoạt trên mặt đất)
- GarageCars (Số xe trong garage)
- TotalBsmtSF (Tổng diện tích gara sử dụng)
- FullBath (Số phòng tắm đầy đủ)

6.2.3 Phương pháp đánh giá

Phương pháp **K-Fold Cross Validation** với $k = 5$ được sử dụng để đánh giá hiệu suất mô hình. Tại mỗi lần lặp, mô hình được huấn luyện trên 4 phần dữ liệu và kiểm tra trên phần còn lại. Giá trị **MAE trung bình** được tính từ 5 lần lặp.
Kết quả thực nghiệm

Đặc trưng	MAE trung bình
OverallQual	33814.4326
GrLivArea	37797.6694
GarageCars	42630.2536
TotalBsmtSF	46523.1152
Fullbath	45076.4198

Bảng 6.3: Kết quả MAE trung bình bằng K-Fold Cross Validation

Đặc trưng tốt nhất
Dựa vào bảng kết quả trên, đặc trưng **OverallQual** có giá trị MAE nhỏ nhất, do đó được chọn làm đặc trưng tốt nhất để xây dựng mô hình hồi quy tuyến tính.
Huấn luyện lại mô hình
Sau khi xác định đặc trưng tốt nhất, mô hình được huấn luyện lại trên toàn bộ tập huấn luyện với công thức:

$$\text{SalePrice} = w_0 + w_1 \cdot \text{OverallQual}$$

Sau khi huấn luyện, các hệ số thu được (làm tròn 3 chữ số thập phân):

$$\text{SalePrice} = 180921.196 + 62837.558 \cdot \text{OverallQual}$$

Kết quả trên tập kiểm tra
Sai số tuyệt đối trung bình trên tập test:

$$MAE = 30903,31$$

Kết quả cho thấy đặc trưng **OverallQual** có khả năng dự đoán tốt nhất trong các đặc trưng đơn được thử nghiệm. Tuy nhiên, sai số vẫn còn khá lớn so với mô hình sử dụng nhiều đặc trưng, cho thấy việc kết hợp nhiều đặc trưng vẫn cần thiết để đạt hiệu suất cao hơn.

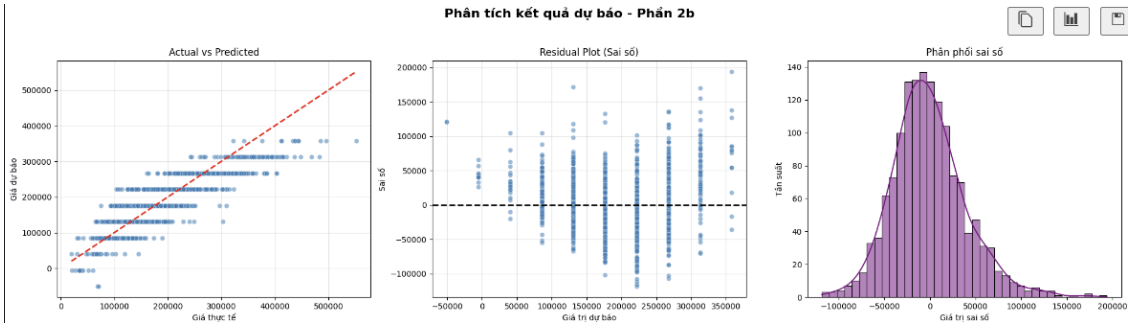

Hình 6.2: Biểu đồ phân tích kết quả dự đoán

6.3 Thiết kế phương án đặc trưng mới (Yêu cầu 2c)

6.3.1 Mô tả

Trong phần này, ba phương án thiết kế đặc trưng khác nhau được xây dựng nhằm cải thiện hiệu suất của mô hình hồi quy tuyến tính. Các phương án tập trung vào ba hướng chính:

- Tạo đặc trưng mới và giảm nhiễu dữ liệu
- Giảm chiều dữ liệu bằng PCA
- Lọc đặc trưng bằng Regularization

Việc đánh giá các phương án được thực hiện bằng phương pháp **K-Fold Cross Validation** nhằm đảm bảo kết quả khách quan và tránh hiện tượng overfitting.
Ngoài ra, quá trình chuẩn hóa dữ liệu được tích hợp trực tiếp trong lớp **KFold** để tránh hiện tượng **data leakage**. Điều này đảm bảo rằng scaler chỉ được fit trên tập huấn luyện của từng fold và sau đó áp dụng lên tập validation tương ứng.

6.3.2 Phương án 1: Feature Engineering + Denoising

Phương án này sử dụng pipeline xử lý dữ liệu đầy đủ nhằm cải thiện chất lượng đặc trưng trước khi huấn luyện mô hình hồi quy tuyến tính. Các bước thực hiện bao gồm:

- Làm sạch dữ liệu (CleanData)

  Xử lý các giá trị thiếu, dữ liệu không hợp lệ và chuẩn hóa định dạng dữ liệu.
- Tạo đặc trưng mới (FeatureCreator)
- Loại bỏ ngoại lai (OutlierRemover)
- Biến đổi dữ liệu (FeatureTransformer)
- Mã hóa dữ liệu (EncodeCategorical) : Sử dụng Full One-hot Encoding cho toàn bộ biến categorical
- Giảm nhiễu và đa cộng tuyến (DenoiseData)
- Sử dụng mô hình dự đoán hồi quy tuyến tính theo phương trình chuẩn

Sau khi xử lý dữ liệu, mô hình Linear Regression được huấn luyện theo phương trình chuẩn:

$$w = (X^T X)^{-1} X^T y$$

Trong đó:

- X là ma trận đặc trưng
- y là vector giá nhà
- w là vector hệ số hồi quy

Phương án này tập trung vào việc cải thiện chất lượng dữ liệu trước khi huấn luyện mô hình, giúp tăng độ chính xác của dự đoán.

6.3.3 Phương án 2: One-hot Encoding + PCA

Trong phương án này, dữ liệu được xử lý theo hướng giảm chiều nhằm giảm số lượng đặc trưng sau khi One-hot Encoding.
Các bước thực hiện bao gồm:

- Làm sạch dữ liệu
- One-hot Encoding toàn bộ biến categorical
- Giảm chiều dữ liệu bằng PCA
- Sử dụng mô hình dự đoán hồi quy tuyến tính theo phương trình chuẩn

Phương pháp PCA giúp giảm số lượng đặc trưng sau khi One-hot Encoding, đồng thời loại bỏ nhiễu và tăng tốc độ huấn luyện.
PCA thực hiện phép chiếu dữ liệu lên không gian mới có số chiều thấp hơn theo công thức:

$$X_{new} = XW$$

Trong đó:

- X là dữ liệu ban đầu
- W là ma trận các vector riêng (eigenvectors)
- X_{new} là dữ liệu sau khi giảm chiều

Ma trận W được tính từ phân rã trị riêng của ma trận hiệp phương sai:

$$Cov(X) = \frac{1}{n} X^T X$$

Sau đó chọn các vector riêng tương ứng với các trị riêng lớn nhất để giữ lại phần lớn phương sai của dữ liệu.
Phương án này giúp:

- Giảm số chiều dữ liệu
- Giảm đa cộng tuyến
- Tăng tốc độ huấn luyện
- Giảm overfitting

Sau khi giảm chiều, mô hình hồi quy tuyến tính được huấn luyện trên tập đặc trưng mới.

6.3.4 Phương án 3: Feature Selection bằng Lasso

Phương án thứ ba sử dụng phương pháp Regularization để lọc đặc trưng và huấn luyện mô hình bằng Gradient Descent. Ý tưởng chính của phương án này là sử dụng Lasso để chọn đặc trưng quan trọng, sau đó huấn luyện mô hình với Ridge nhằm tăng tính ổn định.
Các bước thực hiện bao gồm:

- Làm sạch dữ liệu (CleanData)
- One-hot Encoding cho các biến categorical
- Chuẩn hóa dữ liệu nhằm giúp Gradient Descent hội tụ nhanh và ổn định
- Feature Selection bằng Gradient Descent với hàm loss Lasso
- Huấn luyện mô hình Gradient Descent với hàm loss Ridge

Bước 1: Lọc đặc trưng bằng Lasso
Trong bước này, mô hình sử dụng L1 Regularization (Lasso) để làm thưa vector trọng số. Hàm loss của Lasso được định nghĩa như sau:

$$J(w) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^{p} |w_j|$$

Trong đó:

- n là số mẫu dữ liệu
- p là số đặc trưng
- α là hệ số điều chuẩn

- w_j là hệ số của đặc trưng thứ j

Sau khi huấn luyện, các đặc trưng có hệ số nhỏ hơn ngưỡng:

$$|w_i| < 10^{-4}$$

sẽ bị loại bỏ khỏi mô hình. Điều này giúp giảm số chiều dữ liệu và loại bỏ các đặc trưng không quan trọng.

Bước 2: Huấn luyện mô hình bằng Ridge

Sau khi lọc đặc trưng, mô hình được huấn luyện lại bằng Ridge Regression (L2 Regularization) nhằm tăng độ ổn định của hệ số.

Hàm loss của Ridge:

$$J(w) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^{p} w_j^2$$

Lý do kết hợp Lasso và Ridge:

- Lasso giúp chọn đặc trưng quan trọng
- Ridge giúp giảm overfitting
- Kết hợp hai phương pháp giúp mô hình ổn định hơn

Phương án này đặc biệt hiệu quả khi dữ liệu có nhiều đặc trưng sau khi One-hot Encoding, vì nó giúp giảm số lượng biến và tăng tốc độ huấn luyện.

Sau khi hoàn thành hai bước trên, dữ liệu đã được chọn lọc đặc trưng và sẵn sàng để đánh giá bằng K-Fold Cross Validation.

6.3.5 Đánh giá bằng K-Fold Cross Validation

Phương pháp **K-Fold Cross Validation** với:

$$k = 5$$

được sử dụng để đánh giá các phương án. Ngoài ra, trong mỗi fold:

- Scaler được fit trên tập train của fold
- Sau đó transform trên tập validation

Điều này giúp tránh hiện tượng **data leakage** và đảm bảo kết quả đánh giá chính xác.

6.3.6 Kết quả thực nghiệm

Phương án	MAE trung bình (K-Fold)
Phương án 1 (Feature Engineering + Denoise)	14764.65
Phương án 2 (PCA)	19333.15
Phương án 3 (Lasso Selection)	17119.75

Bảng 6.4: So sánh các phương án thiết kế đặc trưng

Phương án tốt nhất

Dựa trên kết quả trên, phương án 1 cho giá trị MAE nhỏ nhất, do đó được lựa chọn làm mô hình cuối cùng.

6.3.7 Huấn luyện mô hình cuối cùng

Mô hình hồi quy tuyến tính cuối cùng có dạng:

$$\text{SalePrice} = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

Sau khi huấn luyện trên toàn bộ tập dữ liệu huấn luyện, mô hình thu được công thức hồi quy:

$$
\begin{aligned}
\text{SalePrice} = 173742.362 \\
&+ 701.566 \times \text{MS} + 234.750 \times \text{LO} + 4683.901 \times \text{LO1} \\
&+ 11328.903 \times \text{OV} + 6338.442 \times \text{OV1} + 8791.904 \times \text{YE} \\
&+ 1963.934 \times \text{YE1} + 598.200 \times \text{LO2} + 7361.904 \times \text{BS} \\
&+ 7833.617 \times \text{LO3} + 232.367 \times \text{LO4} + 13452.358 \times \text{GR} \\
&- 3970.955 \times \text{BE} + 608.423 \times \text{TO} + 1565.645 \times \text{FI} \\
&- 1024.242 \times \text{GA} + 2805.846 \times \text{GA1} + 3427.796 \times \text{GA2} \\
&+ 1268.335 \times \text{LO5} + 53.223 \times \text{LO6} + 938.161 \times \text{LO7} \\
&+ 1082.483 \times \text{LO8} + 415.407 \times \text{MO} - 101.043 \times \text{YR} \\
&+ 1513.266 \times \text{TO1} + 13279.338 \times \text{TO2} + 2173.308 \times \text{MS1} \\
&- 214.225 \times \text{MS2} + 336.219 \times \text{AL} + 198.379 \times \text{LO9} \\
&- 967.435 \times \text{LA} + 2373.045 \times \text{LO10} + 2225.235 \times \text{LO11} \\
&+ 2125.918 \times \text{LO12} - 1940.454 \times \text{NE} - 2529.281 \times \text{NE1} \\
&- 2190.759 \times \text{NE2} - 2506.525 \times \text{NE3} + 3280.020 \times \text{NE4} \\
&- 2515.795 \times \text{NE5} - 658.532 \times \text{NE6} + 2481.152 \times \text{NE7} \\
&+ 526.713 \times \text{CO} + 3427.398 \times \text{CO1} + 7193.825 \times \text{BL} \\
&+ 1975.535 \times \text{BL1} + 1210.125 \times \text{HO} + 2564.865 \times \text{HO1} \\
&+ 3434.652 \times \text{HO2} - 263.516 \times \text{RO} - 4352.500 \times \text{EX} \\
&- 1149.586 \times \text{EX1} - 3249.074 \times \text{EX2} - 2623.470 \times \text{EX3} \\
&- 3321.004 \times \text{EX4} + 1134.351 \times \text{EX5} - 53.591 \times \text{EX6} \\
&+ 1054.841 \times \text{EX7} - 390.274 \times \text{MA} + 487.824 \times \text{EX8} \\
&- 2396.533 \times \text{EX9} - 1452.083 \times \text{EX10} - 207.982 \times \text{FO} \\
&+ 296.764 \times \text{FO1} + 1962.628 \times \text{FO2} + 2645.783 \times \text{BS1} \\
&- 3846.218 \times \text{BS2} - 2706.544 \times \text{BS3} + 657.129 \times \text{BS4} \\
&- 7186.565 \times \text{BS5} - 1376.051 \times \text{BS6} - 5797.773 \times \text{BS7} \\
&- 10456.643 \times \text{BS8} - 4996.130 \times \text{BS9} - 4055.171 \times \text{BS10} \\
&- 3631.259 \times \text{BS11} - 3847.375 \times \text{BS12} - 4269.896 \times \text{BS13} \\
&- 5786.697 \times \text{BS14} + 7294.607 \times \text{BS15} + 150.295 \times \text{HE} \\
&- 642.929 \times \text{HE1} - 1249.077 \times \text{HE2} + 117.692 \times \text{EL} \\
&- 128.968 \times \text{EL1} + 5417.555 \times \text{KI} + 434.594 \times \text{KI1} \\
&- 412.234 \times \text{KI2} + 3426.652 \times \text{FU} + 454.174 \times \text{FI1} \\
&+ 725.531 \times \text{FI2} + 3125.328 \times \text{GA3} + 2524.982 \times \text{GA4} \\
&+ 4175.751 \times \text{GA5} + 3858.674 \times \text{GA6} - 88.908 \times \text{GA7} \\
&- 1382.608 \times \text{GA8} - 465.740 \times \text{GA9} - 239.338 \times \text{GA10} \\
&+ 1117.249 \times \text{GA11} + 1313.594 \times \text{PA} + 1966.926 \times \text{PA1} \\
&+ 888.634 \times \text{FE} + 1032.547 \times \text{FE1} + 4091.926 \times \text{SA} \\
&- 1286.633 \times \text{SA1} - 1530.480 \times \text{SA2} + 1742.323 \times \text{SA3}
\end{aligned}
$$

Bảng 6.5: Bảng chú thích các biến trong mô hình hồi quy

Nhóm 1		Nhóm 2	
Tên gốc (Feature)	**Ký hiệu**	**Tên gốc (Feature)**	**Ký hiệu**
MSSubClass	MS	BsmtExposure_Av	BS5
LotFrontage	LO	BsmtExposure_Gd	BS6
LotArea	LO1	BsmtExposure_Mn	BS7
OverallQual	OV	BsmtExposure_No	BS8
OverallCond	OV1	BsmtFinType1_ALQ	BS9
YearBuilt	YE	BsmtFinType1_BLQ	BS10
YearRemodAdd	YE1	BsmtFinType1_GLQ	BS11
Log_MasVnrArea	LO2	BsmtFinType1_LwQ	BS12
BsmtFinSF1	BS	BsmtFinType1_Rec	BS13
Log_BsmtFinSF2	LO3	BsmtFinType1_Unf	BS14
Log_BsmtUnfSF	LO4	BsmtFinType2_Unf	BS15
GrLivArea	GR	HeatingQC_Ex	HE
BedroomAbvGr	BE	HeatingQC_Gd	HE1
TotRmsAbvGrd	TO	HeatingQC_TA	HE2
Fireplaces	FI	Electrical_FuseA	EL
GarageYrBlt	GA	Electrical_SBrkr	EL1
GarageCars	GA1	KitchenQual_Ex	KI
GarageArea	GA2	KitchenQual_Gd	KI1
Log_WoodDeckSF	LO5	KitchenQual_TA	KI2
Log_OpenPorchSF	LO6	Functional_Typ	FU
Log_EnclosedPorch	LO7	FireplaceQu_Gd	FI1
Log_ScreenPorch	LO8	FireplaceQu_TA	FI2
MoSold	MO	GarageType_Attchd	GA3
YrSold	YR	GarageType_BuiltIn	GA4
TotalBath	TO1	GarageType_Detchd	GA5
TotalSF	TO2	GarageType_None	GA6
MSZoning_RL	MS1	GarageFinish_Fin	GA7
MSZoning_RM	MS2	GarageFinish_RFn	GA8
Alley_None	AL	GarageFinish_Unf	GA9
LotShape_IR1	LO9	GarageQual_TA	GA10
LandContour_Lvl	LA	GarageCond_TA	GA11
LotConfig_Corner	LO10	PavedDrive_N	PA
LotConfig_CulDSac	LO11	PavedDrive_Y	PA1
LotConfig_Inside	LO12	Fence_MnPrv	FE
Neighborhood_CollgCr	NE	Fence_None	FE1
Neighborhood_Edwards	NE1	SaleType_New	SA
Neighborhood_Gilbert	NE2	SaleType_WD	SA1
Neighborhood_NAmes	NE3	SaleCondition_Abnorml	SA2
Neighborhood_NridgHt	NE4	SaleCondition_Normal	SA3
Neighborhood_OldTown	NE5		
Neighborhood_Sawyer	NE6		
Neighborhood_Somerst	NE7		
Condition1_Feedr	CO		
Condition1_Norm	CO1		
BldgType_1Fam	BL		
BldgType_TwnhsE	BL1		
HouseStyle_1.5Fin	HO		
HouseStyle_1Story	HO1		
HouseStyle_2Story	HO2		
RoofStyle_Gable	RO		
Exterior1st_HdBoard	EX		
Exterior1st_MetalSd	EX1		
Exterior1st_Plywood	EX2		
Exterior1st_VinylSd	EX3		
Exterior1st_Wd Sdng	EX4		
Exterior2nd_HdBoard	EX5		
Exterior2nd_Plywood	EX6		
Exterior2nd_Wd Sdng	EX7		
MasVnrType_BrkFace	MA		
ExterQual_Gd	EX8		
ExterCond_Gd	EX9		
ExterCond_TA	EX10		
Foundation_BrkTil	FO		
Foundation_CBlock	FO1		
Foundation_PConc	FO2		
BsmtQual_Ex	BS1		
BsmtQual_Gd	BS2		
BsmtQual_TA	BS3		
BsmtCond_TA	BS4		

6.3.8 Kết quả trên tập kiểm tra

Sai số tuyệt đối trung bình trên tập test:

$$MAE = 10431.80$$

Kết quả cho thấy việc thiết kế đặc trưng mới giúp cải thiện đáng kể hiệu suất mô hình so với các phương án còn lại. Do đó, phương án 1 được lựa chọn làm mô hình cuối cùng của nghiên cứu.

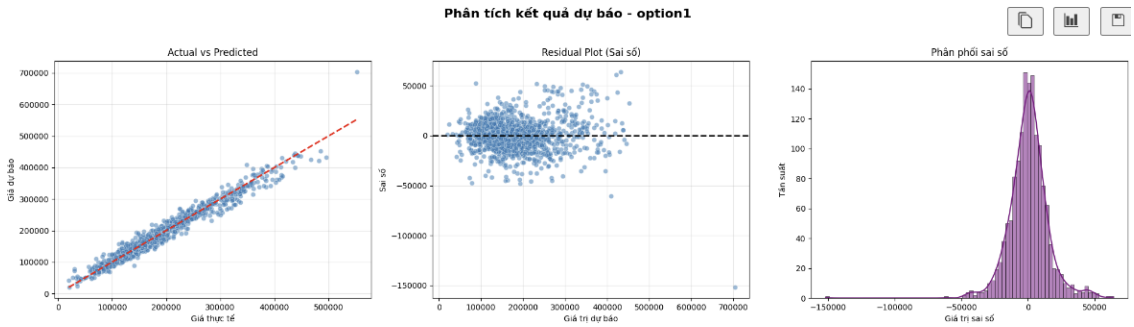

Hình 6.3: Biểu đồ phân tích kết quả dự đoán

6.3.9 So sánh MAE validation với MAE CV của phương án được chọn

```
MAE CV: 14,764.65
MAE Test: 10,431.80
```

Hình 6.4: So sánh phương án được trên MAE CV và MAE Test

Chương 7

KẾT LUẬN

7.1 So sánh kết quả giữa các yêu cầu

Sau quá trình thực nghiệm, kết quả đánh giá trên tập kiểm tra (Test) của ba yêu cầu được tổng hợp trong Bảng 7.1.

Bảng 7.1: Kết quả MAE Test của các yêu cầu

Yêu cầu	Cách tiếp cận	MAE Test
2a	Toàn bộ đặc trưng + Ordinal/One-hot + StandardScaler + Phương trình chuẩn	11.169,55
2b	Lựa chọn đặc trưng đơn tốt nhất	30.903,31
2c	Feature Engineering + Denoising + Full One-hot	**10.431,80**

Từ kết quả trên, có thể rút ra các nhận xét sau:

- **Yêu cầu 2c** đạt kết quả tốt nhất với MAE = 10.431,80, thấp nhất trong ba phương án.
- **Yêu cầu 2a** đạt kết quả khá với MAE = 11.169,55, xếp thứ hai.
- **Yêu cầu 2b** cho kết quả rất kém với MAE = 30.903,31, chênh lệch lớn so với hai phương án còn lại.

Như vậy, thứ tự tốt nhất đến kém nhất là: **2c** > **2a** > **2b**.

7.2 Nhận xét về các phương pháp tiếp cận

7.2.1 Yêu cầu 2a: Toàn bộ đặc trưng

Ưu điểm:

- Đơn giản, dễ triển khai, không làm mất thông tin.
- Kết quả khá ổn định (11.169,55).

Nhược điểm:

- Giữ lại toàn bộ đặc trưng, bao gồm cả nhiễu và các đặc trưng không quan trọng.
- Bị ảnh hưởng bởi hiện tượng đa cộng tuyến.
- Chưa tận dụng được khả năng tạo đặc trưng mới.

7.2.2 Yêu cầu 2b: Lựa chọn đặc trưng đơn tốt nhất

Ưu điểm:

- Rất đơn giản, giảm mạnh số chiều dữ liệu.

Nhược điểm:

- **Kết quả rất kém** (MAE = 30.903,31), không chấp nhận được trong thực tế.
- Một đặc trưng đơn lẻ không đủ để mô tả bài toán phức tạp.
- Làm mất gần như toàn bộ thông tin quan trọng từ dữ liệu.

7.2.3 Yêu cầu 2c: Feature Engineering + Denoising

Ưu điểm:

- **Kết quả tốt nhất** (MAE = 10.431,80).
- Tạo đặc trưng mới giúp mô hình học được các quan hệ phức tạp.
- Loại bỏ ngoại lai (OutlierRemover) và giảm nhiễu (DenoiseData) giúp mô hình ổn định hơn.
- Full One-hot Encoding tránh được việc áp đặt thứ tự sai lên biến danh mục.

Nhược điểm:

- Quy trình phức tạp, nhiều bước xử lý.
- Khó tự động hóa hoàn toàn.
- Chưa được tối ưu siêu tham số một cách có hệ thống.

7.3 Vai trò của biến đổi và lựa chọn đặc trưng

Qua ba yêu cầu, có thể rút ra các kết luận quan trọng sau:

1. **Feature Engineering có tác động tích cực**: Việc tạo đặc trưng mới từ dữ liệu gốc (2c) giúp cải thiện đáng kể độ chính xác so với chỉ dùng đặc trưng thô (2a).
2. **Xử lý nhiễu và ngoại lai là cần thiết**: Các bước loại bỏ outlier và giảm nhiễu giúp mô hình tổng quát hóa tốt hơn.
3. **Lựa chọn đặc trưng quá mạnh tay là phản tác dụng**: Chỉ giữ một đặc trưng (2b) làm mất hầu hết thông tin, dẫn đến kết quả rất kém.

7.4 Kết luận chung

Từ các kết quả thực nghiệm, có thể kết luận:

Yêu cầu 2c (Feature Engineering + Denoising) là phương án tốt nhất,
đạt MAE = 10.431,80 – thấp hơn 2a (11.169,55) và vượt trội hoàn toàn so với 2b (30.903,31).
Không nên sử dụng 2b trong các bài toán thực tế phức tạp.
2a có thể sử dụng nhưng kém hiệu quả hơn 2c.

Như vậy, việc **làm sạch dữ liệu ,tạo đặc trưng mới, loại bỏ nhiễu và xử lý ngoại lai** đóng vai trò then chốt trong việc cải thiện độ chính xác của mô hình hồi quy tuyến tính. Đây là hướng tiếp cận đáng được ưu tiên khi xây dựng các hệ thống dự đoán trong thực tế.

Chương 8

Tài liệu tham khảo

[1] Aurélien Géron (2023). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (3rd ed.). O'Reilly Media.

[2] Vũ Hữu Tiệp (2018). *Machine Learning Cơ bản*. Nhà xuất bản Khoa học và Kỹ thuật.

[3] Trevor Hastie, Robert Tibshirani, and Jerome Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.

[4] Christopher M. Bishop (2006). *Pattern Recognition and Machine Learning*. Springer.

[5] Ian Goodfellow, Yoshua Bengio, and Aaron Courville (2016). *Deep Learning*. MIT Press.

[6] Vũ Hữu Tiệp (2020). *DS102 - Học máy thống kê* (Bài giảng). Đại học Quốc gia TP. Hồ Chí Minh.